

NLP AVANCÉ

(BERT, GPT, Hugging Face)

Chrys NIONGOLO

15 h de notions et d'exemples · 20 h de pratique

5 JOURS

35 H

COLAB T4



NLP avancé · M2 IA

CYBERSUP /2026–2027

Objectifs du cours

Comprendre le traitement du langage naturel et les représentations vectorielles (embeddings).



Mettre en œuvre des modèles pré-entraînés (BERT, GPT) via Hugging Face.

Fine-tuner des LLMs sur des tâches métier (classification, NER, résumé).



Cinq jours, cinq preuves de compréhension

Jour	Question	Preuve produite
1	Comment représenter le texte ?	Recherche TF-IDF + embeddings
2	Comment fonctionne l'attention ?	Calcul QKV + génération contrôlée
3	Comment adapter un encodeur ?	Classification + NER évaluées
4	Comment adapter un petit LLM ?	LoRA support + LoRA résumé évalué
5	Comment défendre un résultat ?	Comparaison + démo + soutenance

3



01 / Du texte à une représentation

Avant de choisir un modèle, définir ce qu'il doit reconnaître.

Matin : repères du NLP, TF-IDF, Word2Vec, tokenisation et embeddings.
Après-midi : comparer TF-IDF et embeddings pour retrouver une fiche FAQ.



Le NLP : faire travailler une machine sur du langage

Partir d'une demande client, choisir une opération, vérifier sa sortie.

TAL : traitement automatique du langage naturel.



NLP (Natural Language Processing) : transformer du texte en sorties vérifiables.

Lire une demande → classer ; trouver une ville → extraire ; condenser → résumer.

Avant le modèle : quelle entrée, quelle sortie, quel critère de réussite ?



Cinq mots pour suivre toute la semaine

Nommer les objets avant de regarder le code.

Document = une unité de texte ; corpus = un ensemble de documents.

SPE
DATA/IA

Token = une unité découpée ; vocabulaire = tokens connus associés à des IDs.

Type = forme distincte ; embedding = vecteur dense appris pour une unité ou un texte.



Compter, apprendre, puis contextualiser

SPE
DATA/IA

Repères	Personnes / équipes	Idée à retenir
1950 / 1966	Turing ; Weizenbaum (MIT)	Questionner ; dialoguer par règles
1957 / 1972	Luhn (IBM) ; Spärck Jones (Cambridge)	Compter et pondérer pour rechercher
2013–2017	Google ; Stanford ; FAIR	Apprendre des vecteurs de mots
2018–2019	AI2 / Washington ; Google	Représenter un mot dans son contexte



TF-IDF : des mots utiles pour retrouver un document

Compter les mots d'un texte, puis atténuer ceux présents partout.

Sac de mots : une coordonnée par terme ; les comptes ignorent l'ordre.



SPE
DATA/IA

TF-IDF (term frequency–inverse document frequency) pondère la fréquence d'un terme selon sa rareté dans le corpus.

Un terme rare distingue parfois mieux, mais peut aussi être du bruit.



Word2Vec : apprendre en prédisant les voisins

SPE
DATA/IA

Word2Vec prédit le mot central depuis le contexte (CBOW, Continuous Bag of Words) ou les voisins depuis le mot central (Skip-gram).



GloVe et fastText : deux idées complémentaires

GloVe : Stanford, 2014. fastText : FAIR, prépublication 2016, revue 2017.

SPE
DATA/IA

Méthode	Information utilisée	Effet attendu
GloVe · Pennington et al.	Statistiques globales de cooccurrence	Vecteurs statiques appris sur le corpus
fastText · Bojanowski et al.	Vecteurs de mots et n-grammes de caractères	Partage d'information entre formes proches

Ces représentations restent statiques ; le contexte d'une nouvelle phrase ne modifie pas leur vecteur.



Un mot, plusieurs sens : passer au contexte

BERT (Bidirectional Encoder Representations from Transformers) construit une représentation contextuelle de chaque token.

« La banque refuse mon prêt. »

SPE
DATA/IA

« La banque de données contient des images. »

Statique : un vecteur fixe par entrée ; contextuel : une représentation liée à l'occurrence.



Diagnostic : que sait cette représentation ?

Relier chaque besoin à une famille, puis donner une limite.

A · Retrouver une fiche grâce à ses mots discriminants.

B · Apprendre des proximités ; C · exploiter les morceaux d'un mot rare.

D · Représenter « banque » différemment selon la phrase.



Même vocabulaire, intention différente

« Je veux annuler » et « Je ne veux pas annuler » ne disent pas la même chose.

Classer : « Mon compte est bloqué depuis mon retour de vacances. »

SPE
DATA/IA

Classer : « Je souhaite retourner un article payé deux fois. »

Repérer la négation, le contexte et les demandes multiples.

Décider ce que doit faire le système lorsqu'il hésite.



Une tâche = une entrée et une sortie vérifiable

SPE
DATA/IA

Tâche	Entrée	Sortie
Classification	Un message	facturation
NER	Commande AB123 à Lyon	AB123 : REF ; Lyon : LIEU
Recherche	Je n'ai rien reçu	Messages proches classés
Résumé	Un échange complet	Faits essentiels conservés
Génération	Question + contexte	Réponse à contrôler



Le jeu de données est déjà une décision de modèle

Décrire les fiches indexées et les requêtes avec leur référence pertinente.



Observer longueurs, ressemblances et ambiguïtés.

Distinguer validation et test final ; documenter l'origine et les limites du corpus.



Une fuite de données peut fabriquer un bon score

Le test doit représenter des situations réellement nouvelles.

Train : ajuster le modèle et son vocabulaire.

SPE
DATA/IA

Validation : choisir les réglages ; test : mesurer une fois le système retenu.

Garder les paraphrases d'un scénario dans la même partition.



Sac de mots : compter avant de comprendre

SPE
DATA/IA

Texte	colis	facture	retard
colis en retard	1	0	1
facture du colis	1	1	0
facture facture	0	2	0

Une colonne par terme ; une ligne par document.



TF-IDF : un terme rare peut mieux distinguer

$$w_{t,d} = \text{tf}(t, d) \ln \left(\frac{N}{\text{df}(t)} \right)$$

SPE
DATA/IA

Pondérer un terme par sa fréquence dans la fiche et sa rareté parmi les fiches.

t : terme ; d : document

$\text{tf}(t,d)$: occurrences de t dans d

$\text{df}(t)$: documents contenant t

N : nombre de documents du corpus

$w(t,d)$: poids TF-IDF, sans unité

$N = 4, \text{df} = 1, \text{tf} = 2 : w = 2 \times \ln(4) \approx 2,773$ avec la formule simplifiée.



Une baseline de recherche tient dans une chaîne claire

Requête → TF-IDF → cosinus avec les fiches → classement.

Requête → TF-IDF → similarité cosinus avec les fiches → classement.

SPE
DATA/IA

Sur une fiche attendue par question : Recall@k = part des questions où elle apparaît dans les k premiers.

MRR = moyenne de $1/\text{rang}$ du premier résultat pertinent ; lire aussi les erreurs.



Lire une confusion au lieu d'admirer un pourcentage

Vrai / prédit	livraison	facturation
livraison	8	2
facturation	1	9

SPE
DATA/IA

17 messages correctement classés sur 20 : accuracy = 85 %.



Tokeniser : choisir les unités lues par le modèle

SPE
DATA/IA

Unité	Exemple illustratif	Compromis
Mot	remboursement	Vocabulaire large
Caractère	r · e · m · b...	Séquences longues
Sous-mot	rembours · ement	Partage entre mots
Octet	Unités d'encodage UTF-8	Couvre les caractères

[Vidéo HF · Tokenizers Overview](#)

21



Prétraiter le français sans effacer le sens

Chaque nettoyage doit être une hypothèse testable.

Chaque nettoyage est une hypothèse à tester sur les erreurs.



Lemmatiser : chercher un lemme ; raciniser : tronquer vers une racine approximative.

Préserver négation, casse utile, accents et références nécessaires à la tâche.



BPE à la main : fusionner les paires fréquentes

SPE
DATA/IA

Mot	Fréquence	Découpage initial
bas	3	b · a · s
basse	2	b · a · s · s · e
bal	1	b · a · l

La paire b·a apparaît 6 fois : première fusion → ba.




Des tokens aux tenseurs : trois objets différents

Objet	Exemple	Rôle
Tokens	bonjour · client	Unités textuelles
input_ids	[101, 1234, 5678, 102, 0]	Indices illustratifs, 0 = padding
attention_mask	[1, 1, 1, 1, 0]	Dernière place = padding
Embeddings	Matrice longueur × dimension	Vecteurs appris



Un embedding rapproche des usages similaires

Espace 2D construit pour expliquer



« Où est mon colis ? »



« Je n'ai rien reçu. »

Usages voisins à vérifier

Un embedding dense représente un usage par un vecteur ; la proximité dépend de l'apprentissage et ne garantit pas l'équivalence.



Cosinus : comparer une direction plutôt qu'une taille

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^T \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2}$$

SPE
DATA/IA

Comparer l'angle entre deux vecteurs après normalisation de leur longueur.

$\mathbf{u}, \mathbf{v}$: vecteurs de même dimension D

$\mathbf{u}^T \mathbf{v}$: produit scalaire, somme de D produits

$\|\mathbf{u}\|_2, \|\mathbf{v}\|_2$: longueurs euclidiennes

$\cos(\mathbf{u}, \mathbf{v})$: similarité comprise entre -1 et 1

$\mathbf{u} = (1,0), \mathbf{v} = (1,1)$: produit = 1 ; normes = 1 et $\sqrt{2}$; cosinus $\approx 0,707$.



Une proximité sémantique peut cacher une contradiction

« J'ai reçu le colis » et « Je n'ai pas reçu le colis » partagent beaucoup de contexte.

Tester une paraphrase, une négation et une demande hors domaine.

SPE
DATA/IA

Séparer similarité de thème et équivalence d'intention.

Lire les trois premiers voisins, pas seulement le meilleur score.

Conserver un petit jeu de requêtes annotées.



Choisir une représentation avec une expérience

Méthode	Force attendue	Test qui la défie
TF-IDF mots	Termes discriminants	Synonyme inédit
TF-IDF caractères	Variantes et fautes	Relation entre propositions
Embedding de phrase	Paraphrases	Négation ou détail critique

SPE
DATA/IA

Même corpus et requêtes. Une FAQ pertinente : $\text{Recall}@k$ = taux de réussite dans les k premiers.



MRR : la position de la première bonne réponse

$$\text{MRR} = \frac{1}{N} \sum_{q=1}^N \text{RR}_q, \quad \text{RR}_q = \frac{1}{r_q}$$

SPE
DATA/IA

Mean Reciprocal Rank : moyenne des inverses des premiers rangs pertinents.

Requête	Premier rang pertinent	Rang réciproque
q ₁	1	1
q ₂	2	0,5
q ₃	4	0,25

N = 3 requêtes évaluées

r_q : rang, compté à partir de 1

Aucun pertinent : RR_q = 0

MRR ≈ 0,583 sur cet exemple



Recall@k : combien de réponses utiles retrouve-t-on ?

$$\text{Recall@}k(q) = \frac{|T_k(q) \cap R(q)|}{|R(q)|}$$

SPE
DATA/IA

Rappel à k : part des documents pertinents présents parmi les k premiers résultats.

q : une requête ; k : nombre de résultats

$T_k(q)$: les k premiers documents renvoyés

$R(q)$: ensemble des documents pertinents

$\cap$: intersection ; $|\dots|$: nombre d'éléments

Moyenne finale : un poids égal par requête

Une seule fiche pertinente : score 0 ou 1

Une fiche attendue : rangs 1, 2, 4 donnent $\text{Recall@}3 = (1 + 1 + 0) / 3 \approx 0,667$.



Vérifier les acquis avant le TP

Pourquoi séparer les paraphrases par groupe ?

Un token est-il toujours un mot ?



Un cosinus de 0,9 signifie-t-il 90 % de vérité ?

Quel exemple pourrait faire gagner TF-IDF face à un embedding ?



TP 1A · Auditer les fiches et les requêtes

Notebook 01_j1_textes_recherche.ipynb · 35 min

Lire les 12 fiches FAQ et associer les premières requêtes à leur fiche.



Distinguer 8 requêtes de validation et 6 requêtes finales.

Observer négation, apostrophe, nombres et segmentation par espaces.

Livrable : hypothèse de recherche et limites de référence.



TP 1B · Construire la recherche lexicale

Notebook 01_j1_textes_recherche.ipynb · 50 min

Ajuster TF-IDF sur les fiches FAQ puis classer les cosinus.



Calculer Recall@1, Recall@3 et MRR sur validation.

Comparer unigrammes et bigrammes à requêtes constantes.

Livrable : classement expliqué et tableau des configurations.



TP 1C · Inspecter et entraîner un tokenizer

Notebook 01_j1_textes_recherche.ipynb · 40 min

Afficher les unités de phrases françaises et repérer les cas limites.

SPE
DATA/IA

Entraîner deux petits BPE sur les textes des fiches.

Comparer vocabulaires cibles de 120 et 240 unités.

Livrable : découpages, longueurs et unités inconnues expliqués.



TP 1D · Comparer, tester et expliquer la recherche

Notebook 01_j1_textes_recherche.ipynb · 115 min

55 min : encoder les fiches et comparer les recherches sur validation.



60 min : analyser, choisir, ouvrir le test final et restituer.

Examiner paraphrase, référence exacte et négation.

Livrable : métriques validation/test et deux erreurs expliquées.



02 / Comprendre les Transformers

Calculer une attention, puis observer un modèle préentraîné.

Matin : Q, K, V ; masques ; architectures ; génération.
Après-midi : attention numérique, modèle masqué et petit LLM.



Prédire la suite : une cible obtenue sans annotation manuelle

Position	Entrée	Cible suivante
1	Le	colis
2	colis	arrive
3	arrive	demain
4	demain	<fin>

Apprentissage auto-supervisé : le texte fournit la cible du token suivant. À chaque position, le modèle estime $P(\text{token suivant} \mid \text{préfixe disponible})$.



Pourquoi permettre aux tokens de se consulter ?

Pour interpréter « il », il faut parfois retrouver un mot éloigné.

Un RNN transmet un état de position en position.


SPE
DATA/IA

L'attention compare des positions et combine leur information selon le contexte.

Le coût de l'attention dense croît approximativement comme le carré de la longueur.



Q, K, V : demander, comparer, récupérer



Q porte la requête, K calcule les compatibilités et V fournit le contenu combiné par l'attention.

Les dimensions racontent le calcul

SPE
DATA/IA

Objet	Forme jouet	Interprétation
X	3×4	3 tokens, 4 caractéristiques
Q, K	3×2	Une tête de dimension $d_k = 2$
V	3×2	Deux valeurs par token
QK^T	3×3	Chaque requête face à chaque clé
A V	3×2	Une sortie par requête



Étape 1 · Calculer les scores de correspondance

Le produit scalaire compare une requête à chaque clé : ce score brut n'est pas encore une probabilité.

SPE
DATA/IA

Requête $q = (1, 0)$	Clé	$q \cdot k$
Position A	$(1, 0)$	1
Position B	$(0, 1)$	0
Position C	$(1, 1)$	1

Les scores bruts comparent une requête aux trois clés.



Étape 2 · Mise à l'échelle et softmax

$$a_i = \frac{\exp(s_i / \sqrt{d_k})}{\sum_{j=1}^n \exp(s_j / \sqrt{d_k})}$$

SPE
DATA/IA

Diviser les scores par $\sqrt{d_k}$ puis appliquer softmax pour obtenir des poids qui somment à un.

$s_i = q^T k_i$: score face à la clé i

d_k : nombre de coordonnées par clé

n : nombre de clés ; i, j : indices

$\exp$: exponentielle ; Σ : somme sur les clés

a_i : poids attribué à la valeur i

Scores $[1 ; 0 ; 1]$, $d_k = 2 \rightarrow$ poids $\approx [0,401 ; 0,198 ; 0,401]$; somme = 1.



Étape 3 · Mélanger les valeurs

$$\mathbf{o} = \sum_{i=1}^3 a_i \mathbf{v}_i \approx \begin{pmatrix} 1,604 \\ 1,198 \end{pmatrix}$$

SPE
DATA/IA

Chaque poids dose la contribution du vecteur $\mathbf{V}$ associé à la représentation de sortie.

Position	Poids	Valeur $\mathbf{V}$
A	0,401	(2, 0)
B	0,198	(0, 2)
C	0,401	(2, 2)

a_i : poids de la position i

$\mathbf{v}_i$: vecteur de valeur à 2 coordonnées

Σ : addition des 3 contributions pondérées

$\mathbf{o}$: vecteur de sortie, dimension 2



Le masque causal empêche de lire la réponse future

Query

Clés : positions lues

	le	colis	arrive	demain
1 · le	0	$-\infty$	$-\infty$	$-\infty$
2 · colis	0	0	$-\infty$	$-\infty$
3 · arrive	0	0	0	$-\infty$
4 · demain	0	0	0	0

0 : accès autorisé


$-\infty$: accès interdit

La ligne 3 lit les positions 1, 2 et 3.

À la position t , le masque causal autorise les positions $\leq t$ et bloque toutes les clés du futur avant softmax.



Plusieurs têtes : plusieurs comparaisons apprises




Deux têtes illustrées ; leurs rôles ne sont pas fixés à l'avance.

Chaque tête calcule une attention avec ses propres projections ; les sorties concaténées sont reprojétées ensemble.

Un bloc ne se limite pas à l'attention

Exemple Post-LN · type BERT



Un bloc combine attention, FFN par position, additions résiduelles et normalisation ; l'ordre exact dépend de l'architecture.



Sans information de position, l'ordre manque

« Le client rembourse le vendeur » $\neq$ « Le vendeur rembourse le client ».

Les embeddings décrivent les tokens ; l'information positionnelle renseigne leur ordre.


SPE
DATA/IA

Positions apprises, sinusoïdales ou relatives sont plusieurs choix d'architecture.

La longueur maximale annoncée ne garantit pas de retrouver chaque détail d'un long document.



Encodeur, décodeur, encodeur-décodeur

SPE
DATA/IA

BERT encode l'entrée valide ; GPT (Generative Pre-trained Transformer) lit le préfixe ; T5 encode la source puis génère la sortie.

[Vidéo HF · The Transformer architecture](#)

48



Préentraînement et adaptation ne répondent pas à la même question

Objectif masqué : retrouver un token caché grâce au contexte disponible.



Objectif causal : prédire le token suivant à partir du préfixe.

Fine-tuning : adapter les paramètres à une tâche ; une nouvelle tête doit apprendre ses labels.


[Vidéo HF · What is Transfer Learning?](#)

49



Décomposer pipeline() pour savoir ce qui se passe

Exemple : classification d'un message



pipeline() relie texte, tokenizer, tenseurs, modèle et post-traitement selon une tâche ; il n'entraîne pas le checkpoint.

50



Décoder : choisir parmi plusieurs suites possibles

SPE
DATA/IA

Réglage	Décision	Effet attendu
Greedy	Choisir le token le plus probable	Pas de tirage ; peut rester erroné
Température T	Régler la concentration avant softmax	Change la distribution, pas la connaissance
Top-k	Garder les k candidats les plus probables	Nombre fixe de candidats
Top-p	Garder une masse cumulée p	Nombre variable, puis renormalisation



Observer une génération avec un protocole

Fixer checkpoint, révision, prompt et chat template.

SPE
DATA/IA

Limiter max_new_tokens, puis comparer greedy et échantillonnage à prompt constant.

Évaluer séparément qualité de rédaction, respect du format et exactitude des faits.



Pouvez-vous expliquer l'attention sans le schéma ?

Pourquoi V doit-il rester distinct de K ?

Quelle dimension utiliser dans $\sqrt{d_k}$ pour une tête de 32 dimensions ?

SPE
DATA/IA

Pourquoi masquer avant le softmax ?

Qu'est-ce qui change quand on augmente la température ?



TP 2A · Refaire QK^T , softmax et AV

Notebook [02_j2_attention_transformers.ipynb](#) · 60 min

Reproduire le calcul numérique à trois clés.

SPE
DATA/IA

Vérifier dimensions, poids positifs et somme par ligne.

Changer Q, K puis V séparément et prédire l'effet.

Livrable : matrices annotées et explication de la sortie.



TP 2B · Rendre le futur inaccessible

Notebook 02_j2_attention_transformers.ipynb · 60 min

Construire un masque causal et visualiser les positions autorisées.

SPE
DATA/IA

Ajouter un cas avec padding.

Comparer deux têtes sur la même séquence.

Livrable : expliquer une fuite et une erreur de dimensions.

55



TP 2C · Observer un encodeur préentraîné

Notebook 02_j2_attention_transformers.ipynb · 60 min

Charger DistilBERT multilingue et son tokenizer.

SPE
DATA/IA

Inspecter les dimensions des entrées et des sorties.

Comparer les suggestions pour plusieurs contextes français.

Livrable : deux réussites, deux limites et leur explication.



TP 2D · Comparer les stratégies de génération

Notebook 02_j2_attention_transformers.ipynb · 60 min

Charger Qwen2.5–0.5B–Instruct et appliquer son chat template.

SPE
DATA/IA

Comparer greedy et échantillonnage à prompt constant.

Mesurer longueur, temps et respect d'une consigne simple.

Livrable : table de sorties et limites du petit modèle.

57



03 / Adapter un modèle à une tâche


Classification de messages et reconnaissance d'entités nommées.

Matin : loss, batchs, Trainer, labels et métriques.

Après-midi : 140 min de classification et 100 min de NER.



Un encodeur et une tête répondent à notre question



L'encodeur produit des représentations ; la tête globale classe, la tête NER étiquette chaque position.

La loss pénalise la probabilité donnée à la bonne réponse

$$\mathcal{L} = -\ln(p_y)$$

SPE
DATA/IA

La cross-entropie compare les logits à la classe vraie : moins elle reçoit de probabilité, plus la pénalité augmente.

y : indice de la vraie classe

p_y : probabilité donnée à cette classe

$\ln$: logarithme naturel, base e

L : loss scalaire, exprimée en nats

$p_y = 0,8 \rightarrow L \approx 0,223$; $p_y = 0,2 \rightarrow L \approx 1,609$: moins croire la vraie classe coûte davantage.



Une étape d'apprentissage en cinq actions

Forward : calculer les prédictions du batch, puis la loss face aux cibles.

Backward : calculer les gradients par rétropropagation.



L'optimiseur met à jour les poids ; remettre les gradients à zéro pour le pas suivant.

Évaluer selon le protocole, sans mettre à jour les poids.

[Vidéo HF · The Trainer API](#)

61



Padding dynamique : payer pour le batch réel

Longueurs	Padding fixe à 128	Padding au max du batch
12, 20, 25	384 positions	75 positions
12, 20, 120	384 positions	360 positions

SPE
DATA/IA

Le collator assemble et complète les séquences du batch. Le masque d'attention distingue tokens réels et padding.



Batch, pas et époque : ne pas mélanger les compteurs

$$B_{\text{eff}} = B_{\text{GPU}} \times A \times G$$

SPE
DATA/IA

L'accumulation regroupe plusieurs micro-batches pour une mise à jour ; elle ne change pas le nombre d'époques.

B_{GPU} : exemples par micro-batch et par GPU

A : nombre de micro-batches accumulés

G : nombre de GPU en parallèle de données

B_{eff} : exemples par mise à jour complète

8 exemples/GPU × 4 micro-batches accumulés × 1 GPU = 32 exemples par mise à jour complète.



Choisir le modèle sur validation, conclure sur test

Définir à l'avance la métrique de sélection.

Comparer les checkpoints sur le même jeu de validation.

Conserver le test hors des choix de réglages.

Documenter taille des jeux, graine et règle de sélection.



Macro-F1 : donner une voix à chaque classe

$$F_1 = \frac{2PR}{P + R}, \quad F_{1,\text{macro}} = \frac{1}{C} \sum_{c=1}^C F_{1,c}$$

SPE
DATA/IA

Calculer précision, rappel et F1 par classe ; macro-F1 donne le même poids à chaque classe.

P : précision ; R : rappel d'une classe

F_1 : moyenne harmonique de P et R

C : nombre de classes ; c : indice

$F_{1,c}$: F1 calculé pour la classe c

$F_{1,\text{macro}}$: moyenne des C scores par classe

TP = 4, FP = 1, FN = 4 → P = 0,8 ; R = 0,5 ; $F_1 \approx 0,615$. Deux F_1 de 0,9 et 0,3 donnent macro = 0,6.



Diagnostiquer avant de multiplier les époques

SPE
DATA/IA

Observation	Hypothèse	Vérification
Train progresse, val régresse	Surapprentissage	Courbes + erreurs
Tout prédit une classe	Labels ou déséquilibre	Distribution + mapping
Loss non finie	Instabilité numérique	Entrées + dtype + réglages
Score presque parfait	Jeu facile ou fuite	Groupes + doublons



NER : retrouver des segments et leur type

SPE
DATA/IA

Mot	Étiquette BIO	Signification
Marie	B-PER	Début d'une personne
Dupont	I-PER	Suite de la personne
habite	O	Hors entité
à	O	Hors entité
Lyon	B-LOC	Début d'un lieu


NER repère les entités et prédit leur type. BIO : B commence un segment, I le prolonge, O est hors entité.

[Vidéo HF · Tasks: Token Classification](#)

67



Un mot annoté peut devenir plusieurs sous-tokens

SPE
DATA/IA

-100 : pas de contribution à la loss

word_id relie les sous-tokens au mot source ; -100 ignore une cible dans la loss.



Deux masques, deux questions différentes

`attention_mask = 0` : position de padding, ignorée comme clé d'attention.

`labels = -100` : position ignorée comme cible de la loss.



Un token peut être visible (masque 1) et ignoré comme cible (label -100).

Le collator complète aussi les labels avec la valeur d'ignorance prévue.



Des logits aux entités : ne pas perdre l'alignement

Batch × longueur × nombre de labels → labels → segments.

Prendre une classe par position selon le décodage retenu.

SPE
DATA/IA

Retirer les positions ignorées avec le même masque que les cibles.

Reconstruire les séquences de labels dans l'ordre des mots.

Inspecter un exemple complet avant de calculer le score global.

70



En NER, la frontière fait partie de la réponse

Référence	Prédiction	Résultat strict
Marie Dupont : PER	Marie : PER	Frontière incorrecte
Lyon : LOC	Lyon : ORG	Type incorrect
AB123 : REF	AB123 : REF	Entité correcte

SPE
DATA/IA

Une entité stricte exige le bon début, la bonne fin et le bon type.



Une convention d'annotation vaut mieux qu'un débat sans règle

Décider si « Mme Dupont » inclut le titre.

Distinguer une ville d'une organisation portant le même nom.

SPE
DATA/IA

Conserver les désaccords et leurs décisions de résolution.

Vérifier les frontières avant de chercher un meilleur modèle.



Comparer un Transformer à la baseline équitabement

SPE
DATA/IA

À conserver	Pourquoi	À rapporter
Mêmes partitions	Même nouveauté évaluée	Tailles et groupes
Mêmes labels	Même tâche	Mapping des classes
Même métrique	Même règle de score	Macro-F1 + classes
Mêmes cas examinés	Comparaison des erreurs	Gains et régressions



Sauvegarder pour recharger, pas seulement pour archiver

Modèle, tokenizer et correspondance des labels vont ensemble.

Conserver configuration, versions, partitions et métriques.

SPE
DATA/IA

Tester une prédiction après rechargement dans un objet neuf.

Exporter les artefacts hors de la session Colab éphémère.



Du batch à la métrique : retrouver les responsabilités

Une loss train faible garantit-elle une bonne validation ?

Pourquoi un token peut-il avoir `attention_mask = 1` et `label = -100` ?

SPE
DATA/IA

Marie au lieu de Marie Dupont : entité exacte ou erreur de frontière ?

Quel objet faut-il recharger avec les poids du classifieur ?



TP 3A · Préparer et entraîner le classifieur

Notebook 03_j3_classification.ipynb · 70 min

Réutiliser les cinq intentions et la séparation par groupes.

SPE
DATA/IA

Inspecter tokenizer, collator, labels et logits.

Lancer une courte adaptation de DistilBERT multilingue.

Livrable : configuration et courbes réellement observées.



TP 3B · Comparer puis transférer à des critiques réelles

Notebook 03_j3_classification.ipynb · 70 min

30 min : comparer les modèles support, analyser et exporter pour J5.

SPE
DATA/IA

40 min : adapter le classifieur au sentiment sur Allociné.

Sous-ensembles : 1 000 train, 200 validation et 200 test.

Livrables distincts : routeur support et modèle de sentiment.



TP 3C · Aligner les mots, les sous-tokens et les labels

Notebook 04_j3_ner.ipynb · 50 min

Lire la convention d'entités du jeu fourni.



Construire l'alignement avec `word_ids()`.

Vérifier tokens spéciaux, continuations et padding à -100.

Livrable : tableau d'alignement validé avant entraînement.



TP 3D · Mesurer des entités complètes

Notebook 04_j3_ner.ipynb · 50 min

Lancer l'entraînement réduit puis reconstruire les séquences.



Vérifier un cas sequeval strict à la main.

Distinguer erreurs de type et erreurs de frontière.

Livrable : métriques, exemples annotés et modèle sauvegardé.



04 / Adapter un petit LLM efficacement

Données de qualité, supervision explicite et budget GPU maîtrisé.

Matin : SFT, LoRA, QLoRA, résumé et fidélité.
Après-midi : 160 min de SFT puis 80 min de résumé.



Prompt, RAG ou fine-tuning : quel problème résoudre ?

Besoin	Premier levier	Limite à vérifier
Clarifier une consigne	Prompt + exemples	Sensibilité à la formulation
Consulter des faits évolutifs	Recherche + contexte (RAG)	Qualité des sources retrouvées
Stabiliser un style ou format	SFT	Qualité et diversité des exemples
Améliorer la tâche	Comparer les approches	Coût et généralisation

Prompt : consigne ; RAG : recherche puis contexte ; SFT : entraînement supervisé.



SFT : montrer les réponses que l'on souhaite obtenir

SFT = Supervised Fine-Tuning : apprendre sur des entrées accompagnées de réponses cibles.

Le modèle conserve l'objectif de prédiction du token suivant.



Les exemples orientent le comportement vers une tâche.

Le format des messages doit correspondre au checkpoint.

La réussite se mesure sur des demandes absentes de l'entraînement.



Une bonne démonstration enseigne aussi les limites

Message : « Mon paiement apparaît deux fois. »

Réponse utile : reconnaître le doublon signalé et demander la vérification nécessaire.

**SPE
DATA/IA**

Réponse risquée : annoncer un remboursement sans preuve.

Conserver le format cible sur toutes les démonstrations.

Inclure des cas ambigus et des informations manquantes.



Curater : garder des exemples utiles et traçables

Curater = sélectionner, vérifier et organiser les exemples, en gardant leur provenance.

Dédupliquer avant la séparation, avec une politique explicite.

SPE
DATA/IA


Contrôler contradictions, format, longueurs et données sensibles.

Séparer par scénario pour limiter les paraphrases partagées.

Conserver des cas de validation et de test sans les réécrire après coup.



Le chat template transforme les rôles en tokens



Le gabarit du checkpoint convertit les rôles en marqueurs ; le tokenizer convertit ensuite le texte en identifiants.



Superviser la réponse, garder la question dans le contexte


	Contexte fourni			Réponse cible	Padding	
Tokens	[SYS]	[USR]	[AST]	livraison	EOS	PAD
Attention	1	1	1	1	1	0
Labels	-100	-100	-100	ID	ID_EOS	-100

Visibilité du contexte $\neq$ supervision de la loss

La question reste dans le contexte ; seules les cibles de réponse et de fin prévues comptent dans la loss.



Le décalage causal ne doit se produire qu'une fois



Les logits à la position t prédisent le token t+1 ; vérifier si le modèle décale déjà les labels.

LoRA : apprendre une petite correction de matrice

$$\mathbf{y} = W_0 \mathbf{x} + \frac{\alpha}{r} B A \mathbf{x}$$

SPE
DATA/IA

LoRA apprend une correction de rang au plus r , avec deux petites matrices ; la base reste gelée.

$\mathbf{x}$: entrée d_{in} ; $\mathbf{y}$: sortie d_{out}

W_0 : matrice gelée, $d_{out} \times d_{in}$

A : $r \times d_{in}$; B : $d_{out} \times r$

r : rang choisi pour la correction

α/r : facteur d'échelle de la correction

$W_0 = I, \mathbf{x} = (2 ; 1), A = [1, -1], B = (0,5 ; 1), \alpha/r = 1 \rightarrow \mathbf{y} = (2,5 ; 2).$



LoRA : combien de paramètres apprend-on ?

$$N_{\text{complet}} = d_{\text{out}} d_{\text{in}}$$

$$N_{\text{LoRA}} = r (d_{\text{in}} + d_{\text{out}})$$

SPE
DATA/IA

Compter les deux petites matrices, puis comparer à la matrice complète.

$d_{\text{in}}, d_{\text{out}}$: dimensions d'entrée et de sortie

r : rang de l'adaptateur


N_{complet} : paramètres de la matrice pleine

N_{LoRA} : paramètres entraînaibles de A et B

$1\,024^2 = 1\,048\,576$; $r = 8 \rightarrow 16\,384$ paramètres LoRA, soit 1,5625 % pour cette matrice.



QLoRA : quantifier la base, entraîner les adaptateurs



Base gelée stockée en NF4 ; calcul dans le dtype choisi ; seuls les adaptateurs LoRA sont entraînés.

La mémoire des poids n'est pas la mémoire totale

$$M_{\text{total}} \approx M_{\text{poids}} + M_{\text{gradients}} + M_{\text{optimiseur}} \\ + M_{\text{activations}} + M_{\text{buffers}}$$

SPE
DATA/IA

La longueur et le micro-batch changent la mémoire des activations, en plus de celle des poids.

M_total : mémoire totale approximative

M_poids : paramètres du modèle et adaptateurs

M_gradients, M_optimiseur : états d'apprentissage

M_activations : valeurs intermédiaires conservées

M_buffers : mémoire de travail et autres tampons

0,5 milliard × 2 octets = 1 Go de poids FP16 idéalisés, avant activations et autres états.



Quatre leviers à régler avec une raison

Levier	Ce qu'il change	Contrepartie
Longueur max	Tokens conservés	Risque de couper la réponse
Micro-batch	Activations simultanées	Plus de passes
Accumulation	Batch effectif	Temps et détails d'optimisation
Checkpointing	Activations stockées	Recalcul supplémentaire

Checkpointing : moins d'activations gardées, plus de recalcul.



Après l'entraînement : base + adaptateur + tokenizer

Sauvegarder l'adaptateur et sa configuration.

Retrouver le même checkpoint de base et la même révision.

SPE
DATA/IA

Recharger l'ensemble dans un objet neuf pour tester l'inférence.

Comparer base et adaptation avec les mêmes prompts et réglages.



Résumer : conserver les faits utiles sous une contrainte

Faits de la source

AB123 reçu mardi.

Un article manque.

Vérification demandée.

Résumé fidèle

AB123 reçu mardi ;
un article manque.
Vérification demandée.

Non étayé par la source

« Remboursement effectué »

Chaque affirmation du résumé doit être étayée par un fait de la source.

[Vidéo HF · Tasks: Summarization](#)

94



ROUGE mesure un recouvrement, pas la vérité

ROUGE-1 compare les tokens ; ROUGE-2 compare les paires de tokens consécutifs.

ROUGE-L utilise la plus longue sous-séquence commune, dans le même ordre.

SPE
DATA/IA

Une paraphrase peut partager peu de mots tout en conservant le fait.

Ajouter « pas » peut inverser un fait tout en gardant un fort recouvrement.



Relier chaque affirmation à une preuve dans la source

Affirmation du résumé	Présente dans la source ?	Verdict
Colis AB123 reçu mardi	Oui	Conservée
Un article manque	Oui	Conservée
Remboursement effectué	Non	Invention
Client demande une vérification	Oui, mais omise	Information perdue

SPE
DATA/IA

Relier chaque affirmation à un fait source. Une phrase plausible mais sans preuve est une invention.



Vérifier ce qui est réellement entraîné et évalué

SFT et LoRA désignent-ils la même chose ?

QLoRA signifie-t-il que tous les calculs se font en 4 bits ?



Pourquoi inspecter les labels du batch SFT ?

Un meilleur ROUGE prouve-t-il un résumé plus fidèle ?



TP 4A · Préparer les démonstrations et la supervision

Notebook 05_j4_sft_lora.ipynb · 80 min

Auditer les paires prompt/completion et les partitions.



Afficher le rendu du chat template de Qwen.

Inspecter le batch réel et les positions labels = -100.

Livrable : cinq exemples validés et masque expliqué.



TP 4B · Entraîner un adaptateur et mesurer l'effet

Notebook 05_j4_sft_lora.ipynb · 80 min

Inspecter modules ciblés et paramètres entraînables.

SPE
DATA/IA

Mesurer une étape avant de lancer la courte expérience.

Comparer base et adaptateur sur les mêmes cas réservés.

Livrable : adaptateur rechargeable, sorties et limites.



TP 4C · Fine-tuner un LoRA dédié au résumé

Notebook 06_j4_resume_evaluation.ipynb · 40 min

Inspecter 16 comptes rendus train, 2 validation et 4 test.

SPE
DATA/IA

Préparer le template et la supervision des réponses de résumé.

Lancer 12 pas LoRA sur le modèle de base, selon le budget réel.

Livrable : adaptateur résumé distinct de celui du support.

100



TP 4D · Comparer extractif, base et résumé adapté

Notebook 06_j4_resume_evaluation.ipynb · 40 min

Évaluer les trois méthodes sur les mêmes 4 textes test réservés.



Confronter ROUGE à fidélité, couverture et format.

Annoter omissions, contradictions et ajouts non étayés.

Livrable : sorties comparées, adaptateur et conclusion prudente.



05 / Évaluer, présenter et défendre un système

SPE
DATA/IA

Le résultat utile est une décision accompagnée de preuves.

Matin : protocole, erreurs, coût, démo et documentation.
Après-midi : mini-projet comparatif et soutenances.

102



Avant le score, écrire le contrat d'évaluation

Définir tâche, population, référence et métrique.



Réserver les données finales aux décisions annoncées.

Préciser quel coût d'erreur compte pour l'usage.



Comparer qualité, coût et fiabilité d'exécution

SPE
DATA/IA

Axe	Mesure possible	Question
Qualité	Macro-F1, F1 entités, grille	La tâche est-elle réussie ?
Coût	Temps, mémoire, taille	À quel prix technique ?
Robustesse	Cas difficiles et hors domaine	Quand cela échoue-t-il ?
Reproductibilité	Rechargement et versions	Peut-on refaire le résultat ?

Benchmark : protocole commun de comparaison. Robustesse : tenue face aux variations.



Une baseline zéro-shot exige aussi un protocole

Classifier parmi cinq classes sans exemples annotés dans le prompt ; fixer consigne, décodage et parsing.

Définir les classes et le format de sortie dans une consigne fixe.

SPE
DATA/IA

Fixer le décodage et la règle de parsing.

Compter les sorties invalides au lieu de les faire disparaître.

Employer les mêmes messages test que pour les autres méthodes.



La métrique dépend de l'unité de réussite

Tâche	Unité évaluée	Mesure de départ
Classification	Message + classe	Macro-F1 et matrice
NER	Segment + type	F1 d'entités strict
Recherche	Requête + documents pertinents	Recall@k défini
Résumé	Faits et texte	ROUGE + grille humaine

SPE
DATA/IA[Vidéo HF · What is the ROUGE metric?](#)

106



Découper les résultats pour trouver les fragilités

Messages courts contre messages longs.

Une intention contre plusieurs demandes.



Formulation fréquente contre paraphrase nouvelle.

Français standard contre fautes, accents manquants ou mélange de langues.



Un petit test produit un résultat incertain

Sur 20 exemples, une erreur de plus change l'accuracy de 5 points.

Rapporter le score et le nombre de cas : un petit test reste fragile.

SPE
DATA/IA

Comparer les modèles sur les mêmes cas, pour isoler leur différence.

Bootstrap : rééchantillonner avec remise les cas observés pour estimer une incertitude.

Séparer la variation des données de celle des entraînements ; aucun cas nouveau n'est créé.



Une grille humaine doit rendre les jugements comparables

Critère	0	1	2
Fidélité	Fait inventé/contredit	Ambiguïté mineure	Faits étayés
Couverture	Information clé absente	Partielle	Essentiel présent
Format	Inexploitable	Correction nécessaire	Conforme
Lisibilité	Confus	Compréhensible	Clair et concis

SPE
DATA/IA



Un LLM juge peut aider, mais il faut aussi le contrôler

Donner une grille précise et les éléments de référence.

Masquer l'identité des systèmes comparés.

Tester l'effet de l'ordre des réponses.

Vérifier un échantillon humain avant d'utiliser ses notes.



Analyser une erreur pour décider d'une action

Erreur observée	Cause à vérifier	Action possible
Mauvais label de référence	Convention ambiguë	Clarifier et tracer
Indice en fin de texte perdu	Troncature	Adapter longueur/segmentation
Sortie LLM invalide	Consigne ou décodage	Fixer format + validation
Fait inventé	Source absente ou ignorée	Contexte + contrôle

SPE
DATA/IA

Tester la robustesse avec des variations contrôlées

Modifier un facteur à la fois pour attribuer les changements de comportement.

Paraphrase : même intention, autre formulation.



Négation : sens modifié avec peu de mots nouveaux.

Référence : même phrase, identifiant différent.

Hors domaine : demande qui ne correspond à aucune classe.



Mesurer la latence dans des conditions compréhensibles

Latence : temps mesuré entre entrée et réponse, avec des bornes explicites.

Séparer chargement initial et inférence après échauffement.

SPE
DATA/IA

p50 = médiane ; p95 = seuil sous lequel se trouvent 95 % des durées observées.

Fixer longueurs, matériel et répétitions ; synchroniser les calculs GPU.



Une démo Gradio rend le comportement inspectable

Gradio crée une interface web autour d'une fonction Python d'inférence.

Un champ texte, une sortie lisible et quelques exemples choisis.

SPE
DATA/IA

Charger le modèle une fois, puis appeler une fonction d'inférence.

Prévoir entrée vide, texte long et message d'erreur compréhensible.

Lancement local au notebook ; partage public désactivé par défaut.



Le livrable doit raconter comment le résultat a été obtenu

Model card : base, adaptation, résultats, usages et limites.



Data card : provenance, construction, partitions et droits.

Artefacts : configuration, tokenizer, prédictions et poids requis.



Publier sur le Hub : rendre l'artefact réutilisable

Hub : dépôts de modèles et de données ; Space : application de démonstration hébergée.

Vérifier les droits du modèle de base et des données.



Pour LoRA, documenter la base requise et les fichiers de l'adaptateur.

Publication facultative ; visibilité privée proposée dans le TP.

Choisir les fichiers à envoyer et documenter leur rechargement.



Mini-projet : une décision défendable en binôme

Critère	Points / 20	Preuve attendue
Protocole et absence de fuite	4	Tâche, groupes, validation, test
Comparaison équitable	4	Méthodes identifiées, mêmes cas
Évaluation et analyse	4	Métriques, erreurs, robustesse
Reproductibilité + démo/card	6	3 points chacun : export et usage
Soutenance individuelle	2	Argumentation des deux membres



Soutenir : problème, preuve, décision, limite

1 min : tâche et protocole.

2 min : comparaison et exemple d'erreur.



1 min : démo avec un cas difficile.

1 min : décision, limite et prochaine expérience.



Avant de conclure : que peut-on réellement affirmer ?

Une démo qui fonctionne prouve-t-elle la généralisation ?

Que faire d'une sortie zéro-shot hors des cinq labels ?

Que signifie un gain d'un exemple sur vingt ?

Quelle preuve permet à un autre binôme de reproduire le résultat ?



TP 5A · Verrouiller le protocole et lancer les références

Notebook 07_j5_projet.ipynb · 75 min

Définir tâche, critères et jeux réservés.

SPE
DATA/IA

Charger la baseline et, si disponible, l'archive du jour 3.

Préparer le zéro-shot avec prompt et parsing fixes.

Livrable : premières prédictions et contrat d'expérience.

120



TP 5B · Tester une amélioration et lire les erreurs

Notebook 07_j5_projet.ipynb · 75 min

Choisir une hypothèse à partir des erreurs de validation.



Modifier un seul facteur et comparer les mêmes cas.

Exécuter le test final après sélection.

Livrable : table comparative, cinq erreurs et mesure de coût.



TP 5C · Préparer une démo et un livrable rechargeable

Notebook 07_j5_projet.ipynb · 40 min

Construire l'interface Gradio et tester ses entrées limites.



Rédiger README, model card et limites des données.

Vérifier les fichiers et le rechargement de l'artefact.

Livrable : archive locale ; publication privée seulement si choisie.



TP 5D · Soutenances, revue croisée et bilan

Notebook 07_j5_projet.ipynb · 50 min

Présenter la tâche, le protocole et les résultats en cinq minutes.

SPE
DATA/IA

Montrer un cas difficile et expliquer une limite.

Faire tester le rechargement ou la démo par un autre groupe.

Conclure par la prochaine expérience la plus utile.



Lexique J1 · Définitions 1

NLP / TAL : Le traitement automatique du langage naturel (TAL), ou Natural Language Processing (NLP), regroupe les méthodes qui transforment des textes en sorties utiles et vérifiables.

langage naturel : Langage utilisé par les personnes pour communiquer, à l'écrit ou à l'oral.



LLM : Large Language Model : modèle de langage doté de nombreux paramètres, entraîné à modéliser des séquences de tokens.

document : Une unité de texte choisie pour une tâche, par exemple un ticket ou une fiche FAQ.



Lexique J1 · Définitions 2

corpus : Un ensemble de documents rassemblés pour une analyse ou un apprentissage.

token : Une unité produite par un tokenizer : mot, morceau de mot, signe ou unité spéciale.

type lexical : Une forme distincte comptée dans un texte ou un corpus, quelle que soit sa fréquence.

vocabulaire : L'inventaire des tokens qu'un tokenizer sait encoder, souvent associé à des identifiants entiers.



Lexique J1 · Définitions 3

embedding : Une représentation apprise sous forme de vecteur dense, pour un token ou une séquence selon le modèle.

recherche d'information : Tâche qui classe des documents selon leur pertinence pour une requête.



sac de mots : Représentation qui compte les termes d'un document sans conserver leur ordre.

TF-IDF : Pondération qui combine la fréquence d'un terme dans un document (TF) et sa rareté parmi les documents (IDF). TF-IDF signifie term frequency–inverse document frequency.



Lexique J1 · Définitions 4

IDF : Inverse document frequency : facteur qui réduit le poids des termes présents dans beaucoup de documents.

lexical / sémantique : Lexical concerne les formes des mots ; sémantique concerne leur sens dans un usage et un contexte.

SPE
DATA/IA

Word2Vec : Famille de méthodes qui apprend des vecteurs de mots en prédisant des mots à partir de leur contexte, ou l'inverse.

CBOW : Continuous Bag of Words : agrège les mots du contexte local pour prédire le mot central.



Lexique J1 · Définitions 5

Skip-gram : Variante de Word2Vec qui part du mot central pour prédire les mots voisins de son contexte.

auto-supervision : Apprentissage où une cible est construite à partir des données elles-mêmes, sans annotation humaine pour chaque exemple.

GloVe : Global Vectors : méthode qui apprend des vecteurs à partir de statistiques globales de cooccurrence des mots.

fastText : Méthode qui représente un mot à partir de son vecteur et de vecteurs de n-grammes de caractères, afin de partager de l'information entre formes proches.



Lexique J1 · Définitions 6

n-gramme de caractères : Séquence de n caractères consécutifs extraite d'une forme écrite.

représentation statique : Vecteur fixe associé à une entrée lexicale dans un modèle donné, quel que soit son contexte d'emploi.



représentation contextuelle : Vecteur interne calculé à partir d'une occurrence et des tokens autour d'elle, selon l'architecture et le contexte autorisé.

BERT : Bidirectional Encoder Representations from Transformers : famille de modèles à encodeur Transformer entraînés notamment avec un objectif de token masqué.



Lexique J1 · Définitions 7

GPT : Generative Pre-trained Transformer : famille de modèles Transformer à décodeur causal qui prédisent la suite à partir d'un préfixe.

distillation : Entraînement d'un modèle élève pour reproduire certaines sorties ou représentations d'un modèle enseignant.

NER : Named Entity Recognition, ou reconnaissance d'entités nommées : repérer dans un texte les segments correspondant à des catégories définies.

classification : Affectation d'une ou plusieurs catégories à une entrée selon une règle de tâche.



Lexique J1 · Définitions 8

jeu de données : Exemples organisés avec les champs nécessaires à une tâche, parfois accompagnés de labels ou de références pertinentes.

pertinence : Règle qui indique quels résultats comptent comme corrects pour une requête donnée.



annotation / label : L'annotation attribue une information de référence à un exemple ; un label est l'étiquette utilisée comme cible.

split : Partition d'un jeu de données en sous-ensembles réservés à des rôles différents, souvent train, validation et test.



Lexique J1 · Définitions 9

fuite de données : Accès, pendant l'apprentissage ou le choix du système, à une information qui ne serait pas disponible dans l'usage ou l'évaluation finale.

train / validation / test : Train sert à ajuster les paramètres ; validation à choisir les réglages ; test à mesurer le système retenu une fois.

SPE
DATA/IA

paraphrase : Reformulation qui conserve le sens pertinent pour la tâche.

vecteur creux : Vecteur dont la plupart des coordonnées sont nulles, souvent obtenu en comptant les termes d'un grand vocabulaire.



Lexique J1 · Définitions 10

n-gramme de tokens : Suite de n tokens consécutifs utilisée comme unité de représentation ou de comparaison.

TF : Term frequency : fréquence ou présence d'un terme à l'intérieur d'un document, selon la variante choisie.

df : Document frequency : nombre de documents du corpus qui contiennent le terme au moins une fois.

N : Nombre total de documents de la collection utilisée pour calculer IDF.



Lexique J1 · Définitions 11

baseline : Système de référence simple et reproductible, utilisé pour juger si une méthode plus complexe apporte un gain.

Recall@k : Rappel à k : fraction des documents pertinents retrouvés parmi les k premiers résultats, calculée par requête puis moyennée.

MRR : Mean Reciprocal Rank : moyenne, sur les requêtes, de l'inverse du rang du premier résultat pertinent ; une absence de résultat pertinent reçoit zéro.

accuracy : Exactitude globale : proportion de prédictions exactement correctes parmi toutes les observations évaluées.



Lexique J1 · Définitions 12

matrice de confusion : Table qui croise classes attendues et prédites pour montrer les bonnes réponses et les confusions.

tokenizer : Composant qui découpe le texte selon un vocabulaire et convertit les unités en identifiants pour un modèle donné.

SPE
DATA/IA

BPE : Byte Pair Encoding : méthode qui construit un vocabulaire en fusionnant progressivement les paires d'unités les plus fréquentes.

WordPiece : Algorithme de sous-mots qui choisit des unités selon un vocabulaire appris et un critère de score de fusion, utilisé notamment dans BERT.



Lexique J1 · Définitions 13

tokenisation unigram : Méthode qui apprend un vocabulaire de sous-mots puis choisit un découpage de forte probabilité, plutôt que de construire uniquement une suite de fusions BPE.

UTF-8 : Encodage de caractères Unicode en unités d'octets de longueur variable.



troncature : Suppression d'une partie des tokens pour respecter une longueur maximale d'entrée.

Unicode : Norme qui attribue des points de code aux caractères de nombreux systèmes d'écriture et symboles.



Lexique J1 · Définitions 14

normalisation Unicode : Transformation définie qui rend certaines représentations Unicode équivalentes sous une forme canonique ou de compatibilité.

lemmatisation : Réduction d'une forme fléchie à son lemme, souvent une forme de dictionnaire, à l'aide d'analyses linguistiques.

racinisation : Réduction heuristique d'un mot à une racine approximative en retirant des suffixes, sans garantir un mot de dictionnaire.

fusion BPE : Étape d'apprentissage qui remplace une paire adjacente fréquente par une nouvelle unité, puis recalcule les fréquences.



Lexique J1 · Définitions 15

tenseur : Tableau numérique à une ou plusieurs dimensions manipulé par le modèle.

batch : Petit groupe d'exemples traités ensemble dans une même opération du modèle.



input_ids : Suite d'identifiants entiers qui représente les tokens après tokenisation.

attention_mask : Masque qui distingue les positions réelles des positions de padding dans une entrée batched.



Lexique J1 · Définitions 16

padding : Tokens ajoutés pour donner aux séquences d'un batch une longueur commune.

représentation dense : Vecteur où la plupart des coordonnées sont non nulles, appris ou calculé pour résumer des caractéristiques.



embedding de phrase : Vecteur unique calculé pour représenter une séquence entière, avec une méthode propre au modèle.

similarité cosinus : Produit scalaire de deux vecteurs normalisés par leurs longueurs ; elle compare leur direction.



Lexique J1 · Définitions 17

produit scalaire : Somme des produits des coordonnées correspondantes de deux vecteurs de même dimension.

norme L2 : Longueur d'un vecteur, calculée par la racine carrée de la somme des carrés de ses coordonnées.

Recall@k et hit rate : Avec une seule FAQ pertinente par requête, Recall@k est égal au hit rate : la proportion de requêtes dont la FAQ attendue figure dans les k premiers résultats.

protocole de comparaison : Conditions fixées pour comparer équitablement plusieurs représentations : mêmes requêtes, corpus, pertinence et mesure.



Lexique J2 · Définitions 1

prédiction du prochain token : Objectif qui apprend à attribuer une distribution aux tokens pouvant suivre un préfixe.

décalage entrée-cible : Construction où les tokens précédents servent d'entrée et le token suivant de cible à chaque position.

SPE
DATA/IA

RNN : Recurrent Neural Network, ou réseau neuronal récurrent : traite une séquence en propageant un état d'une position à la suivante.

attention : Calcul qui compare une représentation à plusieurs positions, puis combine leurs informations avec des poids calculés à partir de projections apprises.



Lexique J2 · Définitions 2

séquence : Suite ordonnée de tokens, généralement munie de positions et de masques.

query (Q), key (K), value (V) : Dans l'attention, Q exprime la position qui interroge, K sert à calculer la compatibilité de chaque position, et V porte le contenu pondéré dans la sortie.

SPE
DATA/IA

projection linéaire : Transformation d'un vecteur par une matrice de paramètres appris, éventuellement suivie d'un biais.

produit matriciel : Opération qui combine les lignes d'une matrice avec les colonnes d'une autre ; les dimensions internes doivent être compatibles.



Lexique J2 · Définitions 3

dimension d_k : Nombre de coordonnées d'une clé et d'une requête dans une tête d'attention donnée.

matrice / transposée : Une matrice est un tableau à deux dimensions ; sa transposée échange lignes et colonnes.

score de compatibilité : Produit scalaire entre une query et une key ; un score plus élevé contribue à un poids d'attention plus élevé après normalisation.

softmax : Fonction qui transforme un vecteur de scores en poids positifs ou nuls dont la somme vaut un, sur les positions autorisées.



Lexique J2 · Définitions 4

mise à l'échelle par $\sqrt{d_k}$: Division des scores de produit scalaire par la racine de la dimension des clés avant softmax afin de contrôler leur amplitude.

somme pondérée : Somme des vecteurs V après multiplication de chacun par son poids d'attention.

SPE
DATA/IA

masque causal : Masque qui interdit à chaque position d'utiliser les clés correspondant aux positions futures, afin de prédire la suite sans la révéler.

attention multi-tête : Calcul de plusieurs attentions en parallèle avec des projections distinctes, puis concaténation et projection de leurs sorties.



Lexique J2 · Définitions 5

concaténation : Assemblage de vecteurs le long d'un axe, sans les moyenner.

MLP / FFN : Multi-Layer Perceptron / Feed-Forward Network : réseau de couches appliqué aux caractéristiques de chaque position, généralement avec une transformation non linéaire.

SPE
DATA/IA

connexion résiduelle : Chemin qui additionne l'entrée d'un sous-bloc à sa transformation, lorsque leurs formes sont compatibles.

normalisation : Opération qui remet à l'échelle les caractéristiques d'une représentation selon une règle du modèle, comme LayerNorm.



Lexique J2 · Définitions 6

information positionnelle : Représentation ou transformation qui donne au modèle un signal sur la position des tokens ou leurs relations d'ordre.

encodeur Transformer : Architecture qui construit des représentations d'une séquence d'entrée en exploitant le contexte autorisé de cette séquence.

décodeur causal : Architecture qui prédit des tokens de sortie à partir du préfixe disponible, avec accès empêché aux tokens futurs.

encodeur-décodeur : Architecture qui encode une séquence source puis génère une séquence cible en consultant la source et le préfixe de sortie.



Lexique J2 · Définitions 7

T5 : Text-to-Text Transfer Transformer : famille encodeur-décodeur qui formule de nombreuses tâches sous forme d'entrée texte vers sortie texte.

préentraînement masqué : Objectif où certains tokens d'entrée sont masqués et prédits en s'appuyant sur le contexte rendu disponible par le modèle.

fine-tuning : Poursuite de l'apprentissage d'un checkpoint préentraîné sur une tâche ou un format ciblé.

tête de classification : Couche de sortie ajoutée à une représentation du modèle pour produire des scores de classes définies.



Lexique J2 · Définitions 8

préentraînement : Apprentissage initial de représentations sur un corpus général avant une adaptation éventuelle à une tâche.

paramètre / hyperparamètre : Un paramètre est appris à partir des données ; un hyperparamètre règle l'architecture ou l'apprentissage.

pipeline : Interface logicielle de haut niveau qui enchaîne préparation des entrées, exécution du modèle et post-traitement pour une tâche choisie.

checkpoint : État enregistré d'un modèle, comprenant ses paramètres et souvent sa configuration après une étape d'apprentissage.



Lexique J2 · Définitions 9

logits : Scores réels non normalisés produits avant softmax pour des classes ou des tokens candidats.

inférence : Utilisation d'un modèle pour calculer une sortie à partir d'une nouvelle entrée.

SPE
DATA/IA

API : Application Programming Interface : interface définie qui permet à un programme d'utiliser une bibliothèque ou un service.

décodage glouton (greedy) : À chaque étape, sélectionne le token de probabilité la plus élevée sans tirer au hasard.



Lexique J2 · Définitions 10

échantillonnage : Choix aléatoire d'un token selon une distribution de probabilités, souvent après filtrage des candidats.

température : Paramètre qui divise les logits avant softmax ; une température basse concentre la distribution et une température haute l'aplatit.

top-k : Filtrage qui ne garde que les k tokens les plus probables avant échantillonnage.

top-p : Échantillonnage à noyau : conserve le plus petit ensemble des tokens les plus probables dont la probabilité cumulée atteint p, puis renormalise.



Lexique J2 · Définitions 11

prompt : Texte ou structure de messages fournie au modèle comme contexte et consigne de génération.



chat template : Formatage propre à un modèle qui transforme les rôles et messages en tokens ou marqueurs attendus par son entraînement.

max_new_tokens : Limite supérieure du nombre de tokens nouveaux générés, sans compter les tokens du prompt.



Lexique J3 · Définitions 1

id2label / label2id : Correspondances sauvegardées entre l'indice numérique d'une classe et son nom, dans les deux sens.

loss (fonction de perte) : Valeur calculée à partir des prédictions et des cibles, que l'entraînement cherche à réduire.

entropie croisée (cross-entropy) : Loss de classification qui pénalise la faible probabilité attribuée à la classe correcte.

forward pass (passe avant) : Calcul qui fait traverser les entrées au modèle pour produire des prédictions.



Lexique J3 · Définitions 2

backpropagation (rétropropagation) : Calcul qui propage l'erreur de la loss vers les paramètres afin d'obtenir leurs gradients.

gradient : Dérivée qui indique comment la loss changerait si un paramètre changeait légèrement.



optimiseur : Algorithme qui utilise les gradients et ses réglages pour mettre à jour les paramètres entraînaables.

AdamW : Optimiseur adaptatif qui estime des moyennes des gradients et sépare la décroissance des poids de l'adaptation du pas.



Lexique J3 · Définitions 3

learning rate (taux d'apprentissage) : Réglage qui détermine l'ampleur des mises à jour des paramètres par l'optimiseur.

Trainer : Classe Hugging Face Transformers qui orchestre l'entraînement et l'évaluation selon une configuration fournie.

SPE
DATA/IA

collator : Fonction qui assemble des exemples en batch et complète au besoin leurs entrées et leurs labels.

pas d'entraînement (step) : Dans ce support, une étape désigne une mise à jour de l'optimiseur ; vérifier la convention du compteur utilisé.



Lexique J3 · Définitions 4

époque (epoch) : Un passage complet sur les exemples du jeu d'entraînement, selon l'ordre et les exclusions définis.

accumulation de gradients : Addition des gradients de plusieurs micro-batches avant d'effectuer une mise à jour.

jeu de validation : Partie réservée au choix du modèle et de ses réglages pendant le développement.

jeu de test : Partie tenue à l'écart des choix de modèle, utilisée pour une estimation finale selon le protocole.



Lexique J3 · Définitions 5

surapprentissage (overfitting) : Situation où un modèle s'ajuste trop aux exemples d'entraînement et généralise moins bien à des exemples nouveaux.

précision : Parmi les exemples prédits positifs pour une classe, part qui appartient réellement à cette classe.

rappel : Parmi les exemples réellement d'une classe, part que le modèle retrouve.

F1 : Moyenne harmonique de la précision et du rappel, qui baisse lorsque l'un des deux est faible.



Lexique J3 · Définitions 6

macro-F1 : Moyenne arithmétique des F1 calculés séparément pour chaque classe, avec le même poids pour chacune.

TP / FP / FN : True Positive : vrai positif ; False Positive : faux positif ; False Negative : faux négatif, pour une classe et une unité d'évaluation données.

micro-F1 / F1 pondéré : Micro-F1 agrège les comptes avant le calcul ; F1 pondéré moyenne les F1 de classe selon leurs effectifs réels.

CPU / GPU / VRAM / OOM : CPU : processeur généraliste ; GPU : processeur adapté aux calculs parallèles ; VRAM : sa mémoire ; OOM : mémoire insuffisante.



Lexique J3 · Définitions 7

BIO : Schéma d'étiquetage : B marque le début d'une entité, I sa continuation et O un token hors entité.

span (segment) : Portion de texte délimitée par un début et une fin, à laquelle on peut associer un type d'entité.

sous-token : Morceau d'un mot produit par le tokenizer, qui peut découper un mot rare en plusieurs unités.

word_id : Indice reliant un sous-token au mot d'origine de la séquence, quand le tokenizer fournit cet alignement.



Lexique J3 · Définitions 8

-100 / ignore_index : Valeur conventionnelle qui indique à certaines fonctions de loss d'ignorer cette position, et non une classe à prédire.

masque de labels : Indicateur des positions dont les cibles participent au calcul de la loss.

SPE
DATA/IA

argmax : Opération qui renvoie l'indice de la valeur maximale d'un tableau de scores.

évaluation stricte d'entité : Règle qui compte une entité comme correcte seulement si son début, sa fin et son type concordent avec la référence.



Lexique J3 · Définitions 9

artefact de modèle : Ensemble de fichiers nécessaires pour identifier, recharger et utiliser un modèle ou son adaptation.

SPE
DATA/IA

graine aléatoire (seed) : Valeur initiale qui rend répétables certains tirages pseudo-aléatoires dans un protocole donné.



Lexique J4 · Définitions 1

RAG (Retrieval-Augmented Generation, génération augmentée par récupération) : Méthode qui recherche des passages pertinents et les ajoute au contexte avant la génération.

SFT (Supervised Fine-Tuning, ajustement fin supervisé) : Adaptation d'un modèle à partir d'exemples d'entrées et de réponses cibles préparés par des personnes ou une règle documentée.

few-shot dans le prompt : Utilisation de quelques exemples de la tâche dans le contexte pour guider la réponse, sans mise à jour des poids.

curation des données : Sélection, vérification et organisation d'exemples dont on documente l'origine et les transformations.



Lexique J4 · Définitions 2

masque de loss : Masque qui détermine quelles positions prédites contribuent à la loss d'entraînement.

décalage causal (causal shift) : Alignement où les logits à une position prédisent le token suivant, sans donner accès à ce token futur.

SPE
DATA/IA

PEFT (Parameter-Efficient Fine-Tuning, ajustement fin économe en paramètres) : Famille de méthodes qui adapte un modèle en entraînant une petite partie des paramètres ou des paramètres ajoutés.

LoRA (Low-Rank Adaptation, adaptation de faible rang) : Méthode PEFT qui représente une correction de poids par le produit de deux petites matrices entraînables, tandis que la matrice de base reste généralement gelée.



Lexique J4 · Définitions 3

rang (rank) : Dimension intermédiaire qui borne le nombre de directions indépendantes représentées par une correction matricielle LoRA.

quantification : Représentation des poids avec moins de bits, en acceptant une approximation contrôlée pour réduire leur stockage.

QLoRA (Quantized Low-Rank Adaptation) : Méthode qui garde une base quantifiée et gelée tout en entraînant des adaptateurs LoRA en précision de calcul adaptée.

NF4 (4-bit NormalFloat) : Format de quantification sur quatre bits conçu pour représenter efficacement des poids dont les valeurs suivent une distribution approximativement normale.



Lexique J4 · Définitions 4

`dtype` (type de données) : Format numérique utilisé pour stocker ou calculer des valeurs, avec une précision et un coût mémoire donnés.

`FP16` / `BF16` : Deux formats flottants de 16 bits : `FP16` offre plus de précision sur la mantisse ; `BF16` offre une plage d'exposants plus large.

`bitsandbytes` : Bibliothèque qui fournit notamment des opérations et des couches quantifiées utilisées dans certains chargements de modèles.

`activations` : Valeurs intermédiaires produites par le réseau pendant la passe avant et parfois conservées pour calculer les gradients.



Lexique J4 · Définitions 5

gradient checkpointing (recalcul des activations) : Technique qui conserve moins d'activations intermédiaires et en recalcule certaines pendant la rétropropagation.

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) : Famille de mesures automatiques qui compare des unités lexicales ou des séquences communes entre un résumé et une référence.

ROUGE-1 : Mesure le recouvrement des unigrammes, c'est-à-dire des unités d'un token, entre candidat et référence.

ROUGE-2 : Mesure le recouvrement des suites de deux tokens consécutifs entre résumé produit et référence.



Lexique J4 · Définitions 6

ROUGE-L : Mesure fondée sur la plus longue sous-séquence commune, qui conserve l'ordre sans exiger que les tokens soient contigus.

résumé extractif : Résumé composé en sélectionnant des phrases ou passages de la source, souvent sans les reformuler.

résumé abstractif : Résumé qui reformule et combine les informations de la source en générant de nouveaux textes.

hallucination (affirmation non étayée) : Contenu généré présenté comme vrai alors qu'il est absent ou contredit par les éléments fournis.



Lexique J4 · Définitions 7

fidélité factuelle : Mesure dans laquelle les affirmations du résumé sont soutenues par la source et n'en contredisent pas les faits.



Lexique J5 · Définitions 1

biais d'évaluation : Distorsion du résultat causée par un échantillon, une annotation, une métrique ou une procédure qui représente mal l'usage visé.

benchmark : Protocole défini de tâches, données, métriques et conditions d'exécution servant à comparer des systèmes.

robustesse : Capacité d'un système à conserver un comportement acceptable lorsque les entrées varient dans les conditions prévues.

reproductibilité : Possibilité de refaire une expérience et d'obtenir des résultats comparables à partir de ses données, réglages et artefacts documentés.



Lexique J5 · Définitions 2

zéro-shot (zero-shot) : Utilisation d'un modèle pour une tâche sans exemple annoté de cette tâche dans son prompt ni adaptation dédiée sur ces exemples.

JSON / parsing : JSON est un format textuel structuré ; le parsing analyse ce texte pour vérifier sa structure et récupérer ses champs.

SPE
DATA/IA

bootstrap (rééchantillonnage bootstrap) : Méthode d'estimation de l'incertitude qui tire plusieurs échantillons avec remise à partir des observations disponibles et recalcule le score.

ablation : Expérience qui retire ou modifie un composant à la fois pour estimer sa contribution, en gardant le reste du protocole comparable.



Lexique J5 · Définitions 3

latence : Temps écoulé entre une requête et la disponibilité de sa réponse, selon les bornes de mesure choisies.

démarrage à froid (cold start) : Première exécution qui inclut des coûts d'initialisation tels que chargement du modèle ou allocation du GPU.

échauffement (warm-up) : Exécutions préalables destinées à laisser le système atteindre son régime stable avant les mesures chronométrées.

p50 / p95 : Percentiles de latence : p50 est la médiane ; p95 est le seuil sous lequel se trouvent 95 % des mesures observées.



Lexique J5 · Définitions 4

Gradio : Bibliothèque Python qui crée une interface web pour appeler une fonction et afficher ses résultats.

model card (fiche de modèle) : Document qui décrit un modèle, son origine, son entraînement, ses évaluations, ses usages prévus et ses limites.



data card (fiche de données) : Document qui précise l'origine, la construction, le contenu, les partitions, les limites et les droits associés à un jeu de données.

licence : Conditions juridiques qui précisent les droits et obligations de réutilisation d'un modèle ou d'un jeu de données.



Lexique J5 · Définitions 5

Hugging Face Hub / Space : Le Hub héberge des dépôts de modèles et de données ; un Space héberge une application de démonstration.

