

NLP AVANCÉ

(BERT, GPT, Hugging Face)

Chrys NIONGOLO

15 h de notions et d'exemples · 20 h de pratique

5 JOURS

35 H

COLAB T4



NLP avancé · M2 IA

CYBERSUP /2026–2027

Objectifs du cours

Comprendre le traitement du langage naturel et les représentations vectorielles (embeddings).



Mettre en œuvre des modèles pré-entraînés (BERT, GPT) via Hugging Face.

Fine-tuner des LLMs sur des tâches métier (classification, NER, résumé).



Cinq jours, cinq preuves de compréhension

Jour	Question	Preuve produite
1	Comment représenter le texte ?	Recherche TF-IDF + embeddings
2	Comment fonctionne l'attention ?	Calcul QKV + génération contrôlée
3	Comment adapter un encodeur ?	Classification + NER évaluées
4	Comment adapter un petit LLM ?	LoRA support + LoRA résumé évalué
5	Comment défendre un résultat ?	Comparaison + démo + soutenance

3



01 / Du texte à une représentation

Avant de choisir un modèle, définir ce qu'il doit reconnaître.

Matin : repères du NLP, TF-IDF, Word2Vec, tokenisation et embeddings.
Après-midi : comparer TF-IDF et embeddings pour retrouver une fiche FAQ.



Le NLP : faire travailler une machine sur du langage

Partir d'une demande client, choisir une opération, vérifier sa sortie.

NLP / TAL : des méthodes pour traiter le langage humain sous forme de données.



Lire une demande → classer ; trouver une ville → extraire ; condenser → résumer.

Avant le modèle : quelle entrée, quelle sortie, quel critère de réussite ?



Cinq mots pour suivre toute la semaine

Nommer les objets avant de regarder le code.

Document = une unité de texte ; corpus = un ensemble de documents.

SPE
DATA/IA

Token = une unité découpée ; vocabulaire = l'ensemble des unités encodables.

Embedding = un vecteur dense appris pour représenter une unité ou un texte.



Compter, apprendre, puis contextualiser

SPE
DATA/IA

Repères	Personnes / équipes	Idée à retenir
1950 / 1966	Turing ; Weizenbaum (MIT)	Questionner ; dialoguer par règles
1957 / 1972	Luhn (IBM) ; Spärck Jones (Cambridge)	Compter et pondérer pour rechercher
2013–2017	Google ; Stanford ; FAIR	Apprendre des vecteurs de mots
2018–2019	AI2 / Washington ; Google	Représenter un mot dans son contexte



TF-IDF : des mots utiles pour retrouver un document

Compter les mots d'un texte, puis atténuer ceux présents partout.

Sac de mots : une coordonnée par terme ; les comptes ignorent l'ordre.



SPE
DATA/IA

TF-IDF : combiner fréquence dans le document et rareté dans le corpus.

Repères : Luhn (IBM, 1957) ; Spärck Jones (Cambridge, 1972).



Word2Vec : apprendre en prédisant les voisins

SPE
DATA/IA

Mikolov et al. · Google, 2013 · Des vecteurs appris par prédiction locale.



GloVe et fastText : deux idées complémentaires

GloVe : Stanford, 2014. fastText : FAIR, prépublication 2016, revue 2017.

SPE
DATA/IA

Méthode	Information utilisée	Question pratique
GloVe · Pennington et al.	Cooccurrences globales de mots	Quels mots apparaissent près des mêmes mots ?
fastText · Bojanowski et al.	Mot et n-grammes de caractères	Des morceaux connus aident-ils un mot rare ?

Ces représentations restent statiques ; le contexte d'une nouvelle phrase ne modifie pas leur vecteur.



Un mot, plusieurs sens : passer au contexte

ELMo : Peters et al., AI2 / Washington, 2018. BERT : Devlin et al., Google, 2018/2019.

« La banque refuse mon prêt. »

SPE
DATA/IA

« La banque de données contient des images. »

Statique : un vecteur par entrée ; contextuel : une représentation liée à l'occurrence.



Diagnostic : que sait cette représentation ?

Relier chaque besoin à une famille, puis donner une limite.

A · Retrouver une fiche grâce à ses mots discriminants.

B · Apprendre des proximités ; C · exploiter les morceaux d'un mot rare.

D · Représenter « banque » différemment selon la phrase.



Même vocabulaire, intention différente

« Je veux annuler » et « Je ne veux pas annuler » ne disent pas la même chose.

Classer : « Mon compte est bloqué depuis mon retour de vacances. »



Classer : « Je souhaite retourner un article payé deux fois. »

Repérer la négation, le contexte et les demandes multiples.

Décider ce que doit faire le système lorsqu'il hésite.



Une tâche = une entrée et une sortie vérifiable

SPE
DATA/IA

Tâche	Entrée	Sortie
Classification	Un message	facturation
NER	Commande AB123 à Lyon	AB123 : REF ; Lyon : LIEU
Recherche	Je n'ai rien reçu	Messages proches classés
Résumé	Un échange complet	Faits essentiels conservés
Génération	Question + contexte	Réponse à contrôler



Le jeu de données est déjà une décision de modèle

Décrire les fiches indexées et les requêtes avec leur référence attendue.

Observer les longueurs, les ressemblances et les ambiguïtés.

SPE
DATA/IA

Distinguer requêtes de validation et requêtes finales.

Documenter l'origine fictive et les limites du corpus.



Une fuite de données peut fabriquer un bon score

Le test doit représenter des situations réellement nouvelles.

Train : apprendre les paramètres et le vocabulaire de la baseline.



Validation : choisir les réglages et le seuil.

Test : mesurer une fois le système retenu.

Garder les paraphrases d'un même scénario dans le même jeu.



Sac de mots : compter avant de comprendre

SPE
DATA/IA

Texte	colis	facture	retard
colis en retard	1	0	1
facture du colis	1	1	0
facture facture	0	2	0

Une colonne par terme ; une ligne par document.



TF-IDF : un terme rare peut mieux distinguer

$$w_{t,d} = \text{tf}(t, d) \ln \left(\frac{N}{\text{df}(t)} \right)$$

SPE
DATA/IA

Un terme compte davantage s'il distingue le document du corpus.

t : terme ; d : document

tf(t,d) : occurrences de t dans d

df(t) : documents contenant t

N : nombre de documents du corpus

w(t,d) : poids TF-IDF, sans unité

N = 4, df = 1, tf = 2 : w = 2 × ln(4) ≈ 2,773 avec la formule simplifiée.



Une baseline de recherche tient dans une chaîne claire

Requête → TF-IDF → cosinus avec les fiches → classement.

Ajuster la représentation sur les fiches de l'index.

SPE
DATA/IA

Évaluer Recall@1, Recall@3 et MRR sur les requêtes de validation.

Lire les erreurs et les termes les plus discriminants.

Conserver cette référence pour comparer les embeddings.



Lire une confusion au lieu d'admirer un pourcentage

Vrai / prédit	livraison	facturation
livraison	8	2
facturation	1	9

SPE
DATA/IA

17 messages correctement classés sur 20 : accuracy = 85 %.



Tokeniser : choisir les unités lues par le modèle

Unité	Exemple illustratif	Compromis
Mot	remboursement	Vocabulaire large
Caractère	r · e · m · b...	Séquences longues
Sous-mot	rembours · ement	Partage entre mots
Octet	Unités d'encodage UTF-8	Couvre les caractères

SPE
DATA/IA

Prétraiter le français sans effacer le sens

Chaque nettoyage doit être une hypothèse testable.

« payé » et « paye » : conserver ou normaliser ?

SPE
DATA/IA

« pas satisfait » : quels mots sont indispensables ?

« Paris » et « paris » : une casse parfois informative.

« commande AB123 » : anonymiser sans détruire la tâche.



BPE à la main : fusionner les paires fréquentes

Mot	Fréquence	Découpage initial
bas	3	b · a · s
basse	2	b · a · s · s · e
bal	1	b · a · l

SPE
DATA/IA

La paire b·a apparaît 6 fois : première fusion → ba.




Des tokens aux tenseurs : trois objets différents

Objet	Exemple	Rôle
Tokens	bonjour · client	Unités textuelles
input_ids	[101, 1234, 5678, 102, 0]	Indices illustratifs, 0 = padding
attention_mask	[1, 1, 1, 1, 0]	Dernière place = padding
Embeddings	Matrice longueur × dimension	Vecteurs appris



Un embedding rapproche des usages similaires

Espace 2D construit pour expliquer



« Où est mon colis ? »



« Je n'ai rien reçu. »

Usages voisins à vérifier

Les positions 2D sont illustratives ; la proximité ne prouve pas un sens identique.



Cosinus : comparer une direction plutôt qu'une taille

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^T \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2}$$

SPE
DATA/IA

Comparer la direction des vecteurs, indépendamment de leur taille.

$\mathbf{u}, \mathbf{v}$: vecteurs de même dimension D

$\mathbf{u}^T \mathbf{v}$: produit scalaire, somme de D produits

$\|\mathbf{u}\|_2, \|\mathbf{v}\|_2$: longueurs euclidiennes

$\cos(\mathbf{u}, \mathbf{v})$: similarité comprise entre -1 et 1

$\mathbf{u} = (1,0), \mathbf{v} = (1,1)$: produit = 1 ; normes = 1 et $\sqrt{2}$; cosinus $\approx 0,707$.



Une proximité sémantique peut cacher une contradiction

« J'ai reçu le colis » et « Je n'ai pas reçu le colis » partagent beaucoup de contexte.

Tester une paraphrase, une négation et une demande hors domaine.

SPE
DATA/IA

Séparer similarité de thème et équivalence d'intention.

Lire les trois premiers voisins, pas seulement le meilleur score.

Conserver un petit jeu de requêtes annotées.



Choisir une représentation avec une expérience

Méthode	Force attendue	Test qui la défie
TF-IDF mots	Termes discriminants	Synonyme inédit
TF-IDF caractères	Variantes et fautes	Relation entre propositions
Embedding de phrase	Paraphrases	Négation ou détail critique

SPE
DATA/IA

Même requêtes, même corpus, même définition de pertinence.



Vérifier les acquis avant le TP

Pourquoi séparer les paraphrases par groupe ?

Un token est-il toujours un mot ?



Un cosinus de 0,9 signifie-t-il 90 % de vérité ?

Quel exemple pourrait faire gagner TF-IDF face à un embedding ?



TP 1A · Auditer les fiches et les requêtes

Notebook 01_j1_textes_recherche.ipynb · 35 min

Lire les 12 fiches FAQ et associer les premières requêtes à leur fiche.



Distinguer 8 requêtes de validation et 6 requêtes finales.

Observer négation, apostrophe, nombres et segmentation par espaces.

Livrable : hypothèse de recherche et limites de référence.



TP 1B · Construire la recherche lexicale

Notebook 01_j1_textes_recherche.ipynb · 50 min

Ajuster TF-IDF sur les fiches FAQ puis classer les cosinus.



Calculer Recall@1, Recall@3 et MRR sur validation.

Comparer unigrammes et bigrammes à requêtes constantes.

Livrable : classement expliqué et tableau des configurations.



TP 1C · Inspecter et entraîner un tokenizer

Notebook 01_j1_textes_recherche.ipynb · 40 min

Afficher les unités de phrases françaises et repérer les cas limites.



Entraîner deux petits BPE sur les textes des fiches.

Comparer vocabulaires cibles de 120 et 240 unités.

Livrable : découpages, longueurs et unités inconnues expliqués.



TP 1D · Comparer, tester et expliquer la recherche

Notebook 01_j1_textes_recherche.ipynb · 115 min

55 min : encoder les fiches et comparer les recherches sur validation.



60 min : analyser, choisir, ouvrir le test final et restituer.

Examiner paraphrase, référence exacte et négation.

Livrable : métriques validation/test et deux erreurs expliquées.



02 / Comprendre les Transformers

Calculer une attention, puis observer un modèle préentraîné.

Matin : Q, K, V ; masques ; architectures ; génération.
Après-midi : attention numérique, modèle masqué et petit LLM.



Prédire la suite : une cible obtenue sans annotation manuelle

Position	Entrée	Cible suivante
1	Le	colis
2	colis	arrive
3	arrive	demain
4	demain	<fin>

Le modèle apprend $P(\text{token suivant} \mid \text{tokens précédents})$.



Pourquoi permettre aux tokens de se consulter ?

Pour interpréter « il », il faut parfois retrouver un mot éloigné.

Un RNN propage un état étape par étape.

SPE
DATA/IA


L'attention construit des liens entre positions d'une séquence.

Le contexte utile varie selon le token et la couche.

Le coût de l'attention dense augmente avec la longueur.



Q, K, V : demander, comparer, récupérer



En self-attention, Q, K et V proviennent de trois projections apprises du même X.

Les dimensions racontent le calcul

SPE
DATA/IA

Objet	Forme jouet	Interprétation
X	3×4	3 tokens, 4 caractéristiques
Q, K	3×2	Une tête de dimension $d_k = 2$
V	3×2	Deux valeurs par token
QK^T	3×3	Chaque requête face à chaque clé
A V	3×2	Une sortie par requête



Étape 1 · Calculer les scores de correspondance

Requête $q = (1, 0)$	Clé	$q \cdot k$
Position A	$(1, 0)$	1
Position B	$(0, 1)$	0
Position C	$(1, 1)$	1

SPE
DATA/IA

Les scores bruts comparent une requête aux trois clés.



Étape 2 · Mise à l'échelle et softmax

$$a_i = \frac{\exp(s_i / \sqrt{d_k})}{\sum_{j=1}^n \exp(s_j / \sqrt{d_k})}$$

SPE
DATA/IA

Transformer les scores d'une requête en poids dont la somme vaut un.

$s_i = q^T k_i$: score face à la clé i

d_k : nombre de coordonnées par clé

n : nombre de clés ; i, j : indices

$\exp$: exponentielle ; Σ : somme sur les clés

a_i : poids attribué à la valeur i

Scores $[1 ; 0 ; 1]$, $d_k = 2 \rightarrow$ poids $\approx [0,401 ; 0,198 ; 0,401]$; somme = 1.



Étape 3 · Mélanger les valeurs

$$\mathbf{o} = \sum_{i=1}^3 a_i \mathbf{v}_i \approx \begin{pmatrix} 1,604 \\ 1,198 \end{pmatrix}$$

SPE
DATA/IA

Chaque poids dose la contribution d'une valeur à la nouvelle représentation.

Position	Poids	Valeur V
A	0,401	(2, 0)
B	0,198	(0, 2)
C	0,401	(2, 2)

a_i : poids de la position i

$\mathbf{v}_i$: vecteur de valeur à 2 coordonnées

Σ : addition des 3 contributions pondérées

$\mathbf{o}$: vecteur de sortie, dimension 2



Le masque causal empêche de lire la réponse future

Clés : positions lues

Query	le	colis	arrive	demain
1 · le	0	$-\infty$	$-\infty$	$-\infty$
2 · colis	0	0	$-\infty$	$-\infty$
3 · arrive	0	0	0	$-\infty$
4 · demain	0	0	0	0

0 : accès autorisé


$-\infty$: accès interdit

La ligne 3 lit les positions 1, 2 et 3.

Le masque s'ajoute aux scores avant softmax : le futur reçoit une probabilité nulle.



Plusieurs têtes : plusieurs comparaisons apprises




Deux têtes illustrées ; leurs rôles ne sont pas fixés à l'avance.

Chaque tête apprend ses projections ; leurs sorties sont concaténées puis reprojctées.

Un bloc ne se limite pas à l'attention

Exemple Post-LN · type BERT



Exemple Post-LN de type BERT ; d'autres Transformers placent la normalisation autrement.

Sans information de position, l'ordre manque

« Le client rembourse le vendeur » $\neq$ « Le vendeur rembourse le client ».

Les embeddings de tokens décrivent les unités.

SPE
DATA/IA


Une information de position distingue leur ordre.

Positions apprises, sinusoïdales ou relatives : plusieurs choix.

Longueur maximale annoncée $\neq$ qualité garantie sur un long document.



Encodeur, décodeur, encodeur-décodeur

SPE
DATA/IA

BERT encode ; GPT génère causalement ; T5 relie encodeur et décodeur par cross-attention.



Préentraînement et adaptation ne répondent pas à la même question

Langage masqué : retrouver un token caché grâce au contexte.

Langage causal : prédire le token suivant à partir du préfixe.

SPE
DATA/IA


Fine-tuning : adapter des paramètres à une tâche ou à un format.

Une tête de classification neuve doit encore apprendre les labels.



Décomposer pipeline() pour savoir ce qui se passe

Exemple : classification d'un message



pipeline() assemble ces étapes ; inspecter chacune aide à localiser une erreur.

Décoder : choisir parmi plusieurs suites possibles

SPE
DATA/IA

Réglage	Décision	Effet attendu
Greedy	Prendre le token le plus probable	Sortie stable pour un calcul donné
Température T	$\text{softmax}(\text{logits} / T)$	T faible concentre la distribution
Top-k	Garder k candidats	Écarter la longue traîne
Top-p	Garder une masse cumulée p	Nombre variable de candidats



Observer une génération avec un protocole

Fixer le modèle, la révision, le prompt et le format de conversation.

Limiter max_new_tokens et observer le motif d'arrêt.

SPE
DATA/IA

Comparer greedy et échantillonnage sur les mêmes demandes.

Séparer qualité de rédaction, respect du format et exactitude.



Pouvez-vous expliquer l'attention sans le schéma ?

Pourquoi V doit-il rester distinct de K ?

Quelle dimension utiliser dans $\sqrt{d_k}$ pour une tête de 32 dimensions ?

SPE
DATA/IA

Pourquoi masquer avant le softmax ?

Qu'est-ce qui change quand on augmente la température ?



TP 2A · Refaire QK^T , softmax et AV

Notebook [02_j2_attention_transformers.ipynb](#) · 60 min

Reproduire le calcul numérique à trois clés.

SPE
DATA/IA

Vérifier dimensions, poids positifs et somme par ligne.

Changer Q, K puis V séparément et prédire l'effet.

Livrable : matrices annotées et explication de la sortie.



TP 2B · Rendre le futur inaccessible

Notebook 02_j2_attention_transformers.ipynb · 60 min

Construire un masque causal et visualiser les positions autorisées.

SPE
DATA/IA

Ajouter un cas avec padding.

Comparer deux têtes sur la même séquence.

Livrable : expliquer une fuite et une erreur de dimensions.



TP 2C · Observer un encodeur préentraîné

Notebook 02_j2_attention_transformers.ipynb · 60 min

Charger DistilBERT multilingue et son tokenizer.

SPE
DATA/IA

Inspecter les dimensions des entrées et des sorties.

Comparer les suggestions pour plusieurs contextes français.

Livrable : deux réussites, deux limites et leur explication.



TP 2D · Comparer les stratégies de génération

Notebook 02_j2_attention_transformers.ipynb · 60 min

Charger Qwen2.5–0.5B–Instruct et appliquer son chat template.

SPE
DATA/IA

Comparer greedy et échantillonnage à prompt constant.

Mesurer longueur, temps et respect d'une consigne simple.

Livrable : table de sorties et limites du petit modèle.

55



03 / Adapter un modèle à une tâche

SPE
DATA/IA

Classification de messages et reconnaissance d'entités nommées.


Matin : loss, batchs, Trainer, labels et métriques.

Après-midi : 140 min de classification et 100 min de NER.

56



Un encodeur et une tête répondent à notre question



Une tête globale prédit une classe ; une tête NER prédit des labels par token.

La loss pénalise la probabilité donnée à la bonne réponse

$$\mathcal{L} = -\ln(p_y)$$

SPE
DATA/IA

Plus la bonne classe reçoit de probabilité, plus sa pénalité diminue.

y : indice de la vraie classe

p_y : probabilité donnée à cette classe

$\ln$: logarithme naturel, base e

$\mathcal{L}$: loss scalaire, exprimée en nats

$p_y = 0,8 \rightarrow \mathcal{L} \approx 0,223$; $p_y = 0,2 \rightarrow \mathcal{L} \approx 1,609$: moins croire la vraie classe coûte davantage.



Une étape d'apprentissage en cinq actions

1. Préparer un batch et calculer les prédictions.
2. Comparer aux cibles pour obtenir la loss.
3. Propager les gradients ; mettre à jour les paramètres.
4. Remettre les gradients à zéro ; 5. évaluer selon le protocole.



Padding dynamique : payer pour le batch réel

Longueurs	Padding fixe à 128	Padding au max du batch
12, 20, 25	384 positions	75 positions
12, 20, 120	384 positions	360 positions

SPE
DATA/IA

Le collator construit le batch rectangulaire.



Batch, pas et époque : ne pas mélanger les compteurs

$$B_{\text{eff}} = B_{\text{GPU}} \times A \times G$$

SPE
DATA/IA

Accumuler plusieurs petits lots augmente le lot d'une mise à jour.

B_{GPU} : exemples par micro-batch et par GPU

A : nombre de micro-batches accumulés

G : nombre de GPU en parallèle de données

B_{eff} : exemples par mise à jour complète

8 exemples/GPU × 4 micro-batches accumulés × 1 GPU = 32 exemples par mise à jour complète.



Choisir le modèle sur validation, conclure sur test

Définir à l'avance la métrique de sélection.

Comparer les checkpoints sur le même jeu de validation.

Conserver le test hors des choix de réglages.

Documenter taille des jeux, graine et règle de sélection.



Macro-F1 : donner une voix à chaque classe

$$F_1 = \frac{2PR}{P + R}, \quad F_{1,\text{macro}} = \frac{1}{C} \sum_{c=1}^C F_{1,c}$$

SPE
DATA/IA

Calculer un F1 par classe, puis leur donner le même poids.

P : précision ; R : rappel d'une classe

F_1 : moyenne harmonique de P et R

C : nombre de classes ; c : indice

$F_{1,c}$: F1 calculé pour la classe c

$F_{1,\text{macro}}$: moyenne des C scores par classe

TP = 4, FP = 1, FN = 4 → P = 0,8 ; R = 0,5 ; $F_1 \approx 0,615$. Deux F_1 de 0,9 et 0,3 donnent macro = 0,6.



Diagnostiquer avant de multiplier les époques

SPE
DATA/IA

Observation	Hypothèse	Vérification
Train progresse, val régresse	Surapprentissage	Courbes + erreurs
Tout prédit une classe	Labels ou déséquilibre	Distribution + mapping
Loss non finie	Instabilité numérique	Entrées + dtype + réglages
Score presque parfait	Jeu facile ou fuite	Groupes + doublons




NER : retrouver des segments et leur type

SPE
DATA/IA

Mot	Étiquette BIO	Signification
Marie	B-PER	Début d'une personne
Dupont	I-PER	Suite de la personne
habite	O	Hors entité
à	O	Hors entité
Lyon	B-LOC	Début d'un lieu



Un mot annoté peut devenir plusieurs sous-tokens

SPE
DATA/IA

-100 : pas de contribution à la loss

Convention du TP : superviser le premier sous-token ; -100 ignore les autres dans la loss.



Deux masques, deux questions différentes

`attention_mask = 0` : cette place correspond au padding de l'entrée.

`labels = -100` : cette position ne contribue pas à la loss.



Un sous-token ignoré dans la loss peut rester visible dans le contexte.

Le collator doit aussi compléter les labels avec la valeur ignorée.



Des logits aux entités : ne pas perdre l'alignement

Batch × longueur × nombre de labels → labels → segments.

Prendre une classe par position selon le décodage retenu.

SPE
DATA/IA

Retirer les positions ignorées avec le même masque que les cibles.

Reconstruire les séquences de labels dans l'ordre des mots.

Inspecter un exemple complet avant de calculer le score global.



En NER, la frontière fait partie de la réponse

Référence	Prédiction	Résultat strict
Marie Dupont : PER	Marie : PER	Frontière incorrecte
Lyon : LOC	Lyon : ORG	Type incorrect
AB123 : REF	AB123 : REF	Entité correcte

SPE
DATA/IA

Évaluer les entités complètes : début, fin et type.



Une convention d'annotation vaut mieux qu'un débat sans règle

Décider si « Mme Dupont » inclut le titre.

Distinguer une ville d'une organisation portant le même nom.

SPE
DATA/IA

Conserver les désaccords et leurs décisions de résolution.

Vérifier les frontières avant de chercher un meilleur modèle.



Comparer un Transformer à la baseline équitabement

SPE
DATA/IA

À conserver	Pourquoi	À rapporter
Mêmes partitions	Même nouveauté évaluée	Tailles et groupes
Mêmes labels	Même tâche	Mapping des classes
Même métrique	Même règle de score	Macro-F1 + classes
Mêmes cas examinés	Comparaison des erreurs	Gains et régressions



Sauvegarder pour recharger, pas seulement pour archiver

Modèle, tokenizer et correspondance des labels vont ensemble.

Conserver configuration, versions, partitions et métriques.

SPE
DATA/IA

Tester une prédiction après rechargement dans un objet neuf.

Exporter les artefacts hors de la session Colab éphémère.



Du batch à la métrique : retrouver les responsabilités

Une loss train faible garantit-elle une bonne validation ?

Pourquoi un token peut-il avoir attention_mask = 1 et label = -100 ?

SPE
DATA/IA

Marie au lieu de Marie Dupont : entité exacte ou erreur de frontière ?

Quel objet faut-il recharger avec les poids du classifieur ?



TP 3A · Préparer et entraîner le classifieur

Notebook 03_j3_classification.ipynb · 70 min

Réutiliser les cinq intentions et la séparation par groupes.



Inspecter tokenizer, collator, labels et logits.

Lancer une courte adaptation de DistilBERT multilingue.

Livrable : configuration et courbes réellement observées.



TP 3B · Comparer puis transférer à des critiques réelles

Notebook 03_j3_classification.ipynb · 70 min

30 min : comparer les modèles support, analyser et exporter pour J5.

SPE
DATA/IA

40 min : adapter le classifieur au sentiment sur Allociné.

Sous-ensembles : 1 000 train, 200 validation et 200 test.

Livrables distincts : routeur support et modèle de sentiment.



TP 3C · Aligner les mots, les sous-tokens et les labels

Notebook 04_j3_ner.ipynb · 50 min

Lire la convention d'entités du jeu fourni.



Construire l'alignement avec `word_ids()`.

Vérifier tokens spéciaux, continuations et padding à -100.

Livrable : tableau d'alignement validé avant entraînement.



TP 3D · Mesurer des entités complètes

Notebook 04_j3_ner.ipynb · 50 min

Lancer l'entraînement réduit puis reconstruire les séquences.



Vérifier un cas sequeval strict à la main.

Distinguer erreurs de type et erreurs de frontière.

Livrable : métriques, exemples annotés et modèle sauvegardé.



04 / Adapter un petit LLM efficacement

Données de qualité, supervision explicite et budget GPU maîtrisé.

Matin : SFT, LoRA, QLoRA, résumé et fidélité.
Après-midi : 160 min de SFT puis 80 min de résumé.



Prompt, RAG ou fine-tuning : quel problème résoudre ?

Besoin	Premier levier	Limite à vérifier
Clarifier une consigne	Prompt + exemples	Sensibilité à la formulation
Consulter des faits évolutifs	Recherche + contexte (RAG)	Qualité des sources retrouvées
Stabiliser un style ou format	SFT	Qualité et diversité des exemples
Améliorer la tâche	Comparer les approches	Coût et généralisation

SPE
DATA/IA



SFT : montrer les réponses que l'on souhaite obtenir

Une consigne, une entrée et une réponse cible cohérente.

Le modèle conserve l'objectif de prédiction du token suivant.

SPE
DATA/IA

Les exemples orientent le comportement vers une tâche.

Le format des messages doit correspondre au checkpoint.

La réussite se mesure sur des demandes absentes de l'entraînement.



Une bonne démonstration enseigne aussi les limites

Message : « Mon paiement apparaît deux fois. »

Réponse utile : reconnaître le doublon signalé et demander la vérification nécessaire.

**SPE
DATA/IA**

Réponse risquée : annoncer un remboursement sans preuve.

Conserver le format cible sur toutes les démonstrations.

Inclure des cas ambigus et des informations manquantes.



Curater : garder des exemples utiles et traçables

Dédupliquer avant la séparation, avec une politique explicite.

Contrôler contradictions, format, longueurs et données sensibles.


SPE
DATA/IA

Séparer par scénario pour limiter les paraphrases partagées.

Conserver des cas de validation et de test sans les réécrire après coup.



Le chat template transforme les rôles en tokens



Exemple de marqueurs Qwen ; utiliser le template associé au checkpoint.

Superviser la réponse, garder la question dans le contexte


	Contexte fourni			Réponse cible		Padding
Tokens	[SYS]	[USR]	[AST]	livraison	EOS	PAD
Attention	1	1	1	1	1	0
Labels	-100	-100	-100	ID	ID_EOS	-100

Visibilité du contexte $\neq$ supervision de la loss

Le prompt reste visible ; la loss porte ici sur la réponse et sa fin de séquence.



Le décalage causal ne doit se produire qu'une fois



Chaque logit à la position t vise le token t+1 ; appliquer ce décalage une seule fois.

LoRA : apprendre une petite correction de matrice

$$\mathbf{y} = W_0 \mathbf{x} + \frac{\alpha}{r} B A \mathbf{x}$$

SPE
DATA/IA

Ajouter une correction entraînable de faible rang à une matrice gelée.

$\mathbf{x}$: entrée d_{in} ; $\mathbf{y}$: sortie d_{out}

W_0 : matrice gelée, $d_{out} \times d_{in}$

A : $r \times d_{in}$; B : $d_{out} \times r$

r : rang choisi pour la correction

α/r : facteur d'échelle de la correction

$W_0 = I, \mathbf{x} = (2 ; 1), A = [1, -1], B = (0,5 ; 1), \alpha/r = 1 \rightarrow \mathbf{y} = (2,5 ; 2).$



LoRA : combien de paramètres apprend-on ?

$$N_{\text{complet}} = d_{\text{out}} d_{\text{in}}$$

$$N_{\text{LoRA}} = r (d_{\text{in}} + d_{\text{out}})$$

SPE
DATA/IA

Compter les deux petites matrices, puis comparer à la matrice complète.

$d_{\text{in}}, d_{\text{out}}$: dimensions d'entrée et de sortie

r : rang de l'adaptateur


N_{complet} : paramètres de la matrice pleine

N_{LoRA} : paramètres entraînaables de A et B

$1\,024^2 = 1\,048\,576$; $r = 8 \rightarrow 16\,384$ paramètres LoRA, soit 1,5625 % pour cette matrice.



QLoRA : quantifier la base, entraîner les adaptateurs



Base stockée en NF4 ; calcul en FP16 ici ; seuls les adaptateurs sont entraînables.

La mémoire des poids n'est pas la mémoire totale

$$M_{\text{total}} \approx M_{\text{poids}} + M_{\text{gradients}} + M_{\text{optimiseur}} \\ + M_{\text{activations}} + M_{\text{buffers}}$$

SPE
DATA/IA

Les poids ne représentent qu'une partie de la mémoire nécessaire.

M_total : mémoire totale approximative

M_poids : paramètres du modèle et adaptateurs

M_gradients, M_optimiseur : états d'apprentissage

M_activations : valeurs intermédiaires conservées

M_buffers : mémoire de travail et autres tampons

0,5 milliard × 2 octets = 1 Go de poids FP16 idéalisés, avant activations et autres états.



Quatre leviers à régler avec une raison

Levier	Ce qu'il change	Contrepartie
Longueur max	Tokens conservés	Risque de couper la réponse
Micro-batch	Activations simultanées	Plus de passes
Accumulation	Batch effectif	Temps et détails d'optimisation
Checkpointing	Activations stockées	Recalcul supplémentaire

SPE
DATA/IA



Après l'entraînement : base + adaptateur + tokenizer

Sauvegarder l'adaptateur et sa configuration.

Retrouver le même checkpoint de base et la même révision.




Recharger l'ensemble dans un objet neuf pour tester l'inférence.

Comparer base et adaptation avec les mêmes prompts et réglages.



Résumer : conserver les faits utiles sous une contrainte

SPE
DATA/IA

Chaque affirmation du résumé doit être étayée par un fait de la source.



ROUGE mesure un recouvrement, pas la vérité

ROUGE-1 : recouvrement d'unités lexicales selon la tokenisation.

ROUGE-L : similarité fondée sur une sous-séquence commune.

SPE
DATA/IA

Une bonne paraphrase peut partager peu de mots.

Une phrase presque identique peut inverser un fait crucial.



Relier chaque affirmation à une preuve dans la source

Affirmation du résumé	Présente dans la source ?	Verdict
Colis AB123 reçu mardi	Oui	Conservée
Un article manque	Oui	Conservée
Remboursement effectué	Non	Invention
Client demande une vérification	Oui, mais omise	Information perdue

SPE
DATA/IA



Vérifier ce qui est réellement entraîné et évalué

SFT et LoRA désignent-ils la même chose ?

QLoRA signifie-t-il que tous les calculs se font en 4 bits ?



Pourquoi inspecter les labels du batch SFT ?

Un meilleur ROUGE prouve-t-il un résumé plus fidèle ?



TP 4A · Préparer les démonstrations et la supervision

Notebook 05_j4_sft_lora.ipynb · 80 min

Auditer les paires prompt/completion et les partitions.



Afficher le rendu du chat template de Qwen.

Inspecter le batch réel et les positions labels = -100.

Livrable : cinq exemples validés et masque expliqué.



TP 4B · Entraîner un adaptateur et mesurer l'effet

Notebook 05_j4_sft_lora.ipynb · 80 min

Inspecter modules ciblés et paramètres entraînables.

SPE
DATA/IA

Mesurer une étape avant de lancer la courte expérience.

Comparer base et adaptateur sur les mêmes cas réservés.

Livrable : adaptateur rechargeable, sorties et limites.



TP 4C · Fine-tuner un LoRA dédié au résumé

Notebook 06_j4_resume_evaluation.ipynb · 40 min

Inspecter 16 comptes rendus train, 2 validation et 4 test.



Préparer le template et la supervision des réponses de résumé.

Lancer 12 pas LoRA sur le modèle de base, selon le budget réel.

Livrable : adaptateur résumé distinct de celui du support.



TP 4D · Comparer extractif, base et résumé adapté

Notebook 06_j4_resume_evaluation.ipynb · 40 min

Évaluer les trois méthodes sur les mêmes 4 textes test réservés.



Confronter ROUGE à fidélité, couverture et format.

Annoter omissions, contradictions et ajouts non étayés.

Livrable : sorties comparées, adaptateur et conclusion prudente.



05 / Évaluer, présenter et défendre un système

SPE
DATA/IA

Le résultat utile est une décision accompagnée de preuves.

Matin : protocole, erreurs, coût, démo et documentation.
Après-midi : mini-projet comparatif et soutenances.

100



Avant le score, écrire le contrat d'évaluation

Quelle tâche et quelle population de messages ?

Quelle référence, quelle métrique et quel coût d'erreur ?

Quelles données sont réservées à la décision finale ?

Quelle preuve ferait changer notre choix de modèle ?



Comparer qualité, coût et fiabilité d'exécution

SPE
DATA/IA

Axe	Mesure possible	Question
Qualité	Macro-F1, F1 entités, grille	La tâche est-elle réussie ?
Coût	Temps, mémoire, taille	À quel prix technique ?
Robustesse	Cas difficiles et hors domaine	Quand cela échoue-t-il ?
Reproductibilité	Rechargement et versions	Peut-on refaire le résultat ?



Une baseline zéro-shot exige aussi un protocole

Demander au LLM un label parmi les cinq classes, sans exemples d'entraînement dans le prompt.

Définir les classes et le format de sortie dans une consigne fixe.

SPE
DATA/IA

Fixer le décodage et la règle de parsing.

Compter les sorties invalides au lieu de les faire disparaître.

Employer les mêmes messages test que pour les autres méthodes.



La métrique dépend de l'unité de réussite

SPE
DATA/IA

Tâche	Unité évaluée	Mesure de départ
Classification	Message + classe	Macro-F1 et matrice
NER	Segment + type	F1 d'entités strict
Recherche	Requête + documents pertinents	Recall@k défini
Résumé	Faits et texte	ROUGE + grille humaine



Découper les résultats pour trouver les fragilités

Messages courts contre messages longs.

Une intention contre plusieurs demandes.



Formulation fréquente contre paraphrase nouvelle.

Français standard contre fautes, accents manquants ou mélange de langues.



Un petit test produit un résultat incertain

Sur 20 exemples, une erreur de plus change l'accuracy de 5 points.

Rapporter le nombre d'exemples avec chaque score.

SPE
DATA/IA

Comparer les mêmes cas, pas deux échantillons différents.

Distinguer variation de données et variation d'entraînement.

Utiliser rééchantillonnage ou répétitions seulement avec un protocole clair.



Une grille humaine doit rendre les jugements comparables

Critère	0	1	2
Fidélité	Fait inventé/contredit	Ambiguïté mineure	Faits étayés
Couverture	Information clé absente	Partielle	Essentiel présent
Format	Inexploitable	Correction nécessaire	Conforme
Lisibilité	Confus	Compréhensible	Clair et concis

SPE
DATA/IA



Un LLM juge peut aider, mais il faut aussi le contrôler

Donner une grille précise et les éléments de référence.

Masquer l'identité des systèmes comparés.

Tester l'effet de l'ordre des réponses.

Vérifier un échantillon humain avant d'utiliser ses notes.



Analyser une erreur pour décider d'une action

SPE
DATA/IA

Erreur observée	Cause à vérifier	Action possible
Mauvais label de référence	Convention ambiguë	Clarifier et tracer
Indice en fin de texte perdu	Troncature	Adapter longueur/segmentation
Sortie LLM invalide	Consigne ou décodage	Fixer format + validation
Fait inventé	Source absente ou ignorée	Contexte + contrôle



Tester la robustesse avec des variations contrôlées

Changer une chose à la fois pour savoir ce qui casse.

Paraphrase : même intention, autre formulation.



Négation : sens modifié avec peu de mots nouveaux.

Référence : même phrase, identifiant différent.

Hors domaine : demande qui ne correspond à aucune classe.



Mesurer la latence dans des conditions compréhensibles

Séparer chargement initial et inférence à chaud.

Fixer batch, longueur d'entrée et longueur de sortie.

SPE
DATA/IA

Sur GPU, synchroniser correctement la mesure du calcul.

Rapporter matériel, répétitions et distribution des temps.



Une démo Gradio rend le comportement inspectable

Un champ texte, une sortie lisible et quelques exemples choisis.

Charger le modèle une fois, puis appeler une fonction d'inférence.

SPE
DATA/IA

Prévoir entrée vide, texte long et message d'erreur compréhensible.

Lancement local au notebook ; partage public désactivé par défaut.



Le livrable doit raconter comment le résultat a été obtenu

README : objectif, lancement et limites.

Model card : base, adaptation, données, métriques et usages prévus.

SPE
DATA/IA

Data card : origine, schéma, construction, partitions et licence.

Artefacts : configuration, prédictions, modèle ou adaptateur et tokenizer.



Publier sur le Hub : rendre l'artefact réutilisable

Vérifier la licence du modèle de base et des données.

Choisir explicitement visibilité et fichiers à envoyer.



Pour LoRA, documenter la dépendance au checkpoint de base.

Publication facultative ; dépôt privé proposé dans le TP.



Mini-projet : une décision défendable en binôme

SPE
DATA/IA

Critère	Points / 20	Preuve attendue
Protocole et absence de fuite	4	Tâche, groupes, validation, test
Comparaison équitable	4	Méthodes identifiées, mêmes cas
Évaluation et analyse	4	Métriques, erreurs, robustesse
Reproductibilité + démo/card	6	3 points chacun : export et usage
Soutenance individuelle	2	Argumentation des deux membres



Soutenir : problème, preuve, décision, limite

1 min : tâche et protocole.

2 min : comparaison et exemple d'erreur.

1 min : démo avec un cas difficile.

1 min : décision, limite et prochaine expérience.



Avant de conclure : que peut-on réellement affirmer ?

Une démo qui fonctionne prouve-t-elle la généralisation ?

Que faire d'une sortie zéro-shot hors des cinq labels ?

Que signifie un gain d'un exemple sur vingt ?

Quelle preuve permet à un autre binôme de reproduire le résultat ?



TP 5A · Verrouiller le protocole et lancer les références

Notebook 07_j5_projet.ipynb · 75 min

Définir tâche, critères et jeux réservés.

SPE
DATA/IA

Charger la baseline et, si disponible, l'archive du jour 3.

Préparer le zéro-shot avec prompt et parsing fixes.

Livrable : premières prédictions et contrat d'expérience.



TP 5B · Tester une amélioration et lire les erreurs

Notebook 07_j5_projet.ipynb · 75 min

Choisir une hypothèse à partir des erreurs de validation.



Modifier un seul facteur et comparer les mêmes cas.

Exécuter le test final après sélection.

Livrable : table comparative, cinq erreurs et mesure de coût.



TP 5C · Préparer une démo et un livrable rechargeable

Notebook 07_j5_projet.ipynb · 40 min

Construire l'interface Gradio et tester ses entrées limites.

SPE
DATA/IA

Rédiger README, model card et limites des données.

Vérifier les fichiers et le rechargement de l'artefact.

Livrable : archive locale ; publication privée seulement si choisie.

120



TP 5D · Soutenances, revue croisée et bilan

Notebook 07_j5_projet.ipynb · 50 min

Présenter la tâche, le protocole et les résultats en cinq minutes.

SPE
DATA/IA

Montrer un cas difficile et expliquer une limite.

Faire tester le rechargement ou la démo par un autre groupe.

Conclure par la prochaine expérience la plus utile.

