

# NLP AVANCÉ

## (BERT, GPT, Hugging Face)

Chrys NIONGOLO

15 h de notions et d'exemples · 20 h de pratique

5 JOURS

35 H

COLAB T4



NLP avancé · M2 IA

**CYBERSUP** /2026–2027

# Objectifs du cours

Comprendre le traitement du langage naturel et les représentations vectorielles (embeddings).



Mettre en œuvre des modèles pré-entraînés (BERT, GPT) via Hugging Face.

Fine-tuner des LLMs sur des tâches métier (classification, NER, résumé).



# Cinq jours, cinq preuves de compréhension

| Jour | Question                         | Preuve produite                   |
|------|----------------------------------|-----------------------------------|
| 1    | Comment représenter le texte ?   | Recherche TF-IDF + embeddings     |
| 2    | Comment fonctionne l'attention ? | Calcul QKV + génération contrôlée |
| 3    | Comment adapter un encodeur ?    | Classification + NER évaluées     |
| 4    | Comment adapter un petit LLM ?   | LoRA support + LoRA résumé évalué |
| 5    | Comment défendre un résultat ?   | Comparaison + démo + soutenance   |

3



# 01 / Du texte à une représentation

Avant de choisir un modèle, définir ce qu'il doit reconnaître.

Matin : données, baseline, tokenisation, embeddings.

Après-midi : comparer TF-IDF et embeddings pour retrouver une fiche FAQ.



# Même vocabulaire, intention différente

« Je veux annuler » et « Je ne veux pas annuler » ne disent pas la même chose.

Classer : « Mon compte est bloqué depuis mon retour de vacances. »

SPE  
DATA/IA

Classer : « Je souhaite retourner un article payé deux fois. »

Repérer la négation, le contexte et les demandes multiples.

Décider ce que doit faire le système lorsqu'il hésite.



# Une tâche = une entrée et une sortie vérifiable

SPE  
DATA/IA

| Tâche          | Entrée                | Sortie                     |
|----------------|-----------------------|----------------------------|
| Classification | Un message            | facturation                |
| NER            | Commande AB123 à Lyon | AB123 : REF ; Lyon : LIEU  |
| Recherche      | Je n'ai rien reçu     | Messages proches classés   |
| Résumé         | Un échange complet    | Faits essentiels conservés |
| Génération     | Question + contexte   | Réponse à contrôler        |



# Le jeu de données est déjà une décision de modèle

Décrire les fiches indexées et les requêtes avec leur référence attendue.

Observer les longueurs, les ressemblances et les ambiguïtés.



Distinguer requêtes de validation et requêtes finales.

Documenter l'origine fictive et les limites du corpus.



# Une fuite de données peut fabriquer un bon score

**Le test doit représenter des situations réellement nouvelles.**

Train : apprendre les paramètres et le vocabulaire de la baseline.



Validation : choisir les réglages et le seuil.

Test : mesurer une fois le système retenu.

Garder les paraphrases d'un même scénario dans le même jeu.



# Sac de mots : compter avant de comprendre

| Texte            | colis | facture | retard |
|------------------|-------|---------|--------|
| colis en retard  | 1     | 0       | 1      |
| facture du colis | 1     | 1       | 0      |
| facture facture  | 0     | 2       | 0      |

SPE  
DATA/IA

Une colonne par terme ; une ligne par document.



# TF-IDF : un terme rare peut mieux distinguer

$$w_{t,d} = \text{tf}(t, d) \ln \left( \frac{N}{\text{df}(t)} \right)$$

SPE  
DATA/IA

Un terme compte davantage s'il distingue le document du corpus.

t : terme ; d : document

tf(t,d) : occurrences de t dans d

df(t) : documents contenant t

N : nombre de documents du corpus

w(t,d) : poids TF-IDF, sans unité

**N = 4, df = 1, tf = 2 : w = 2 × ln(4) ≈ 2,773 avec la formule simplifiée.**



# Une baseline de recherche tient dans une chaîne claire

**Requête → TF-IDF → cosinus avec les fiches → classement.**

Ajuster la représentation sur les fiches de l'index.

SPE  
DATA/IA

Évaluer Recall@1, Recall@3 et MRR sur les requêtes de validation.

Lire les erreurs et les termes les plus discriminants.

Conserver cette référence pour comparer les embeddings.



# Lire une confusion au lieu d'admirer un pourcentage

| Vrai / prédit | livraison | facturation |
|---------------|-----------|-------------|
| livraison     | 8         | 2           |
| facturation   | 1         | 9           |

SPE  
DATA/IA

17 messages correctement classés sur 20 : accuracy = 85 %.



# Tokeniser : choisir les unités lues par le modèle

| Unité     | Exemple illustratif     | Compromis             |
|-----------|-------------------------|-----------------------|
| Mot       | remboursement           | Vocabulaire large     |
| Caractère | r · e · m · b...        | Séquences longues     |
| Sous-mot  | rembours · ement        | Partage entre mots    |
| Octet     | Unités d'encodage UTF-8 | Couvre les caractères |

SPE  
DATA/IA

# Prétraiter le français sans effacer le sens

**Chaque nettoyage doit être une hypothèse testable.**

« payé » et « paye » : conserver ou normaliser ?

SPE  
DATA/IA

« pas satisfait » : quels mots sont indispensables ?

« Paris » et « paris » : une casse parfois informative.

« commande AB123 » : anonymiser sans détruire la tâche.



# BPE à la main : fusionner les paires fréquentes

| Mot   | Fréquence | Découpage initial |
|-------|-----------|-------------------|
| bas   | 3         | b · a · s         |
| basse | 2         | b · a · s · s · e |
| bal   | 1         | b · a · l         |

SPE  
DATA/IA

La paire b·a apparaît 6 fois : première fusion → ba.



# Des tokens aux tenseurs : trois objets différents


SPE  
DATA/IA

| Objet          | Exemple                      | Rôle                              |
|----------------|------------------------------|-----------------------------------|
| Tokens         | bonjour · client             | Unités textuelles                 |
| input_ids      | [101, 1234, 5678, 102, 0]    | Indices illustratifs, 0 = padding |
| attention_mask | [1, 1, 1, 1, 0]              | Dernière place = padding          |
| Embeddings     | Matrice longueur × dimension | Vecteurs appris                   |



# Un embedding rapproche des usages similaires

Espace 2D construit pour expliquer



« Où est mon colis ? »



« Je n'ai rien reçu. »

Usages voisins à vérifier

Les positions 2D sont illustratives ; la proximité ne prouve pas un sens identique.



# Cosinus : comparer une direction plutôt qu'une taille

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^T \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2}$$



Comparer la direction des vecteurs, indépendamment de leur taille.

$\mathbf{u}, \mathbf{v}$  : vecteurs de même dimension  $D$

$\mathbf{u}^T \mathbf{v}$  : produit scalaire, somme de  $D$  produits

$\|\mathbf{u}\|_2, \|\mathbf{v}\|_2$  : longueurs euclidiennes

$\cos(\mathbf{u}, \mathbf{v})$  : similarité comprise entre  $-1$  et  $1$

$\mathbf{u} = (1,0), \mathbf{v} = (1,1)$  : produit = 1 ; normes = 1 et  $\sqrt{2}$  ; cosinus  $\approx 0,707$ .



# Une proximité sémantique peut cacher une contradiction

« J'ai reçu le colis » et « Je n'ai pas reçu le colis » partagent beaucoup de contexte.

Tester une paraphrase, une négation et une demande hors domaine.

SPE  
DATA/IA

Séparer similarité de thème et équivalence d'intention.

Lire les trois premiers voisins, pas seulement le meilleur score.

Conserver un petit jeu de requêtes annotées.



# Choisir une représentation avec une expérience

| Méthode             | Force attendue       | Test qui la défie           |
|---------------------|----------------------|-----------------------------|
| TF-IDF mots         | Termes discriminants | Synonyme inédit             |
| TF-IDF caractères   | Variantes et fautes  | Relation entre propositions |
| Embedding de phrase | Paraphrases          | Négation ou détail critique |

SPE  
DATA/IA

Même requêtes, même corpus, même définition de pertinence.



# Vérifier les acquis avant le TP

Pourquoi séparer les paraphrases par groupe ?

Un token est-il toujours un mot ?



Un cosinus de 0,9 signifie-t-il 90 % de vérité ?

Quel exemple pourrait faire gagner TF-IDF face à un embedding ?



# TP 1A · Auditer les fiches et les requêtes

**Notebook 01\_j1\_textes\_recherche.ipynb · 35 min**

Lire les 12 fiches FAQ et associer les premières requêtes à leur fiche.



Distinguer 8 requêtes de validation et 6 requêtes finales.

Observer négation, apostrophe, nombres et segmentation par espaces.

Livrable : hypothèse de recherche et limites de référence.



# TP 1B · Construire la recherche lexicale

**Notebook 01\_j1\_textes\_recherche.ipynb · 50 min**

Ajuster TF-IDF sur les fiches FAQ puis classer les cosinus.



Calculer Recall@1, Recall@3 et MRR sur validation.

Comparer unigrammes et bigrammes à requêtes constantes.

Livrable : classement expliqué et tableau des configurations.



# TP 1C · Inspecter et entraîner un tokenizer

**Notebook 01\_j1\_textes\_recherche.ipynb · 40 min**

Afficher les unités de phrases françaises et repérer les cas limites.



Entraîner deux petits BPE sur les textes des fiches.

Comparer vocabulaires cibles de 120 et 240 unités.

Livrable : découpages, longueurs et unités inconnues expliqués.



# TP 1D · Comparer, tester et expliquer la recherche

**Notebook 01\_j1\_textes\_recherche.ipynb · 115 min**

55 min : encoder les fiches et comparer les recherches sur validation.



60 min : analyser, choisir, ouvrir le test final et restituer.

Examiner paraphrase, référence exacte et négation.

Livrable : métriques validation/test et deux erreurs expliquées.



# 02 / Comprendre les Transformers

Calculer une attention, puis observer un modèle préentraîné.

Matin : Q, K, V ; masques ; architectures ; génération.  
Après-midi : attention numérique, modèle masqué et petit LLM.



# Prédire la suite : une cible obtenue sans annotation manuelle

| Position | Entrée | Cible suivante |
|----------|--------|----------------|
| 1        | Le     | colis          |
| 2        | colis  | arrive         |
| 3        | arrive | demain         |
| 4        | demain | <fin>          |

Le modèle apprend  $P(\text{token suivant} \mid \text{tokens précédents})$ .



# Pourquoi permettre aux tokens de se consulter ?

Pour interpréter « il », il faut parfois retrouver un mot éloigné.

Un RNN propage un état étape par étape.

SPE  
DATA/IA


L'attention construit des liens entre positions d'une séquence.

Le contexte utile varie selon le token et la couche.

Le coût de l'attention dense augmente avec la longueur.



# Q, K, V : demander, comparer, récupérer



En self-attention, Q, K et V proviennent de trois projections apprises du même X.

# Les dimensions racontent le calcul

SPE  
DATA/IA

| Objet  | Forme jouet  | Interprétation                   |
|--------|--------------|----------------------------------|
| X      | $3 \times 4$ | 3 tokens, 4 caractéristiques     |
| Q, K   | $3 \times 2$ | Une tête de dimension $d_k = 2$  |
| V      | $3 \times 2$ | Deux valeurs par token           |
| $QK^T$ | $3 \times 3$ | Chaque requête face à chaque clé |
| A V    | $3 \times 2$ | Une sortie par requête           |



# Étape 1 · Calculer les scores de correspondance

| Requête $q = (1, 0)$ | Clé      | $q \cdot k$ |
|----------------------|----------|-------------|
| Position A           | $(1, 0)$ | 1           |
| Position B           | $(0, 1)$ | 0           |
| Position C           | $(1, 1)$ | 1           |

SPE  
DATA/IA

Les scores bruts comparent une requête aux trois clés.



## Étape 2 · Mise à l'échelle et softmax

$$a_i = \frac{\exp(s_i / \sqrt{d_k})}{\sum_{j=1}^n \exp(s_j / \sqrt{d_k})}$$

SPE  
DATA/IA

Transformer les scores d'une requête en poids dont la somme vaut un.

$s_i = q^T k_i$  : score face à la clé  $i$

$d_k$  : nombre de coordonnées par clé

$n$  : nombre de clés ;  $i, j$  : indices

$\exp$  : exponentielle ;  $\Sigma$  : somme sur les clés

$a_i$  : poids attribué à la valeur  $i$

Scores  $[1 ; 0 ; 1]$ ,  $d_k = 2 \rightarrow$  poids  $\approx [0,401 ; 0,198 ; 0,401]$  ; somme = 1.



## Étape 3 · Mélanger les valeurs

$$\mathbf{o} = \sum_{i=1}^3 a_i \mathbf{v}_i \approx \begin{pmatrix} 1,604 \\ 1,198 \end{pmatrix}$$

SPE  
DATA/IA

Chaque poids dose la contribution d'une valeur à la nouvelle représentation.

| Position | Poids | Valeur V |
|----------|-------|----------|
| A        | 0,401 | (2, 0)   |
| B        | 0,198 | (0, 2)   |
| C        | 0,401 | (2, 2)   |

$a_i$  : poids de la position  $i$

$\mathbf{v}_i$  : vecteur de valeur à 2 coordonnées

$\Sigma$  : addition des 3 contributions pondérées

$\mathbf{o}$  : vecteur de sortie, dimension 2



# Le masque causal empêche de lire la réponse future

**Clés : positions lues**

| Query      | le | colis     | arrive    | demain    |
|------------|----|-----------|-----------|-----------|
| 1 · le     | 0  | $-\infty$ | $-\infty$ | $-\infty$ |
| 2 · colis  | 0  | 0         | $-\infty$ | $-\infty$ |
| 3 · arrive | 0  | 0         | 0         | $-\infty$ |
| 4 · demain | 0  | 0         | 0         | 0         |

**0 : accès autorisé**


**$-\infty$  : accès interdit**

La ligne 3 lit les positions 1, 2 et 3.

Le masque s'ajoute aux scores avant softmax : le futur reçoit une probabilité nulle.



# Plusieurs têtes : plusieurs comparaisons apprises




Deux têtes illustrées ; leurs rôles ne sont pas fixés à l'avance.

Chaque tête apprend ses projections ; leurs sorties sont concaténées puis reprojétées.

# Un bloc ne se limite pas à l'attention

Exemple Post-LN · type BERT



Exemple Post-LN de type BERT ; d'autres Transformers placent la normalisation autrement.

# Sans information de position, l'ordre manque

« Le client rembourse le vendeur »  $\neq$  « Le vendeur rembourse le client ».

Les embeddings de tokens décrivent les unités.

SPE  
DATA/IA


Une information de position distingue leur ordre.

Positions apprises, sinusoïdales ou relatives : plusieurs choix.

Longueur maximale annoncée  $\neq$  qualité garantie sur un long document.



# Encodeur, décodeur, encodeur-décodeur

SPE  
DATA/IA

BERT encode ; GPT génère causalement ; T5 relie encodeur et décodeur par cross-attention.



# Préentraînement et adaptation ne répondent pas à la même question

Langage masqué : retrouver un token caché grâce au contexte.

Langage causal : prédire le token suivant à partir du préfixe.


Fine-tuning : adapter des paramètres à une tâche ou à un format.

Une tête de classification neuve doit encore apprendre les labels.



# Décomposer pipeline() pour savoir ce qui se passe

Exemple : classification d'un message



pipeline() assemble ces étapes ; inspecter chacune aide à localiser une erreur.

# Décoder : choisir parmi plusieurs suites possibles

SPE  
DATA/IA

| Réglage       | Décision                            | Effet attendu                      |
|---------------|-------------------------------------|------------------------------------|
| Greedy        | Prendre le token le plus probable   | Sortie stable pour un calcul donné |
| Température T | $\text{softmax}(\text{logits} / T)$ | T faible concentre la distribution |
| Top-k         | Garder k candidats                  | Écarter la longue traîne           |
| Top-p         | Garder une masse cumulée p          | Nombre variable de candidats       |



# Observer une génération avec un protocole

Fixer le modèle, la révision, le prompt et le format de conversation.

Limiter max\_new\_tokens et observer le motif d'arrêt.

SPE  
DATA/IA

Comparer greedy et échantillonnage sur les mêmes demandes.

Séparer qualité de rédaction, respect du format et exactitude.



# Pouvez-vous expliquer l'attention sans le schéma ?

Pourquoi V doit-il rester distinct de K ?

Quelle dimension utiliser dans  $\sqrt{d_k}$  pour une tête de 32 dimensions ?

SPE  
DATA/IA

Pourquoi masquer avant le softmax ?

Qu'est-ce qui change quand on augmente la température ?



# TP 2A · Refaire $QK^T$ , softmax et AV

**Notebook 02\_j2\_attention\_transformers.ipynb · 60 min**

Reproduire le calcul numérique à trois clés.

SPE  
DATA/IA

Vérifier dimensions, poids positifs et somme par ligne.

Changer Q, K puis V séparément et prédire l'effet.

Livrable : matrices annotées et explication de la sortie.



# TP 2B · Rendre le futur inaccessible

**Notebook 02\_j2\_attention\_transformers.ipynb · 60 min**

Construire un masque causal et visualiser les positions autorisées.

SPE  
DATA/IA

Ajouter un cas avec padding.

Comparer deux têtes sur la même séquence.

Livrable : expliquer une fuite et une erreur de dimensions.



# TP 2C · Observer un encodeur préentraîné

**Notebook 02\_j2\_attention\_transformers.ipynb · 60 min**

Charger DistilBERT multilingue et son tokenizer.

SPE  
DATA/IA

Inspecter les dimensions des entrées et des sorties.

Comparer les suggestions pour plusieurs contextes français.

Livrable : deux réussites, deux limites et leur explication.



# TP 2D · Comparer les stratégies de génération

**Notebook 02\_j2\_attention\_transformers.ipynb · 60 min**

Charger Qwen2.5–0.5B–Instruct et appliquer son chat template.

SPE  
DATA/IA

Comparer greedy et échantillonnage à prompt constant.

Mesurer longueur, temps et respect d'une consigne simple.

Livrable : table de sorties et limites du petit modèle.

47



# 03 / Adapter un modèle à une tâche

SPE  
DATA/IA

Classification de messages et reconnaissance d'entités nommées.


Matin : loss, batchs, Trainer, labels et métriques.

Après-midi : 140 min de classification et 100 min de NER.

48



# Un encodeur et une tête répondent à notre question



Une tête globale prédit une classe ; une tête NER prédit des labels par token.

# La loss pénalise la probabilité donnée à la bonne réponse

$$\mathcal{L} = -\ln(p_y)$$

SPE  
DATA/IA

Plus la bonne classe reçoit de probabilité, plus sa pénalité diminue.

$y$  : indice de la vraie classe

$p_y$  : probabilité donnée à cette classe

$\ln$  : logarithme naturel, base  $e$

$\mathcal{L}$  : loss scalaire, exprimée en nats

$p_y = 0,8 \rightarrow \mathcal{L} \approx 0,223$  ;  $p_y = 0,2 \rightarrow \mathcal{L} \approx 1,609$  : moins croire la vraie classe coûte davantage.

50



# Une étape d'apprentissage en cinq actions

1. Préparer un batch et calculer les prédictions.
2. Comparer aux cibles pour obtenir la loss.
3. Propager les gradients ; mettre à jour les paramètres.
4. Remettre les gradients à zéro ; 5. évaluer selon le protocole.



# Padding dynamique : payer pour le batch réel

| Longueurs   | Padding fixe à 128 | Padding au max du batch |
|-------------|--------------------|-------------------------|
| 12, 20, 25  | 384 positions      | 75 positions            |
| 12, 20, 120 | 384 positions      | 360 positions           |

SPE  
DATA/IA

Le collator construit le batch rectangulaire.



# Batch, pas et époque : ne pas mélanger les compteurs

$$B_{\text{eff}} = B_{\text{GPU}} \times A \times G$$

SPE  
DATA/IA

Accumuler plusieurs petits lots augmente le lot d'une mise à jour.

$B_{\text{GPU}}$  : exemples par micro-batch et par GPU

$A$  : nombre de micro-batches accumulés

$G$  : nombre de GPU en parallèle de données

$B_{\text{eff}}$  : exemples par mise à jour complète

**8 exemples/GPU × 4 micro-batches accumulés × 1 GPU = 32 exemples par mise à jour complète.**



# Choisir le modèle sur validation, conclure sur test

Définir à l'avance la métrique de sélection.

Comparer les checkpoints sur le même jeu de validation.

Conserver le test hors des choix de réglages.

Documenter taille des jeux, graine et règle de sélection.



# Macro-F1 : donner une voix à chaque classe

$$F_1 = \frac{2PR}{P + R}, \quad F_{1,\text{macro}} = \frac{1}{C} \sum_{c=1}^C F_{1,c}$$

SPE  
DATA/IA

Calculer un F1 par classe, puis leur donner le même poids.

P : précision ; R : rappel d'une classe

$F_1$  : moyenne harmonique de P et R

C : nombre de classes ; c : indice

$F_{1,c}$  : F1 calculé pour la classe c

$F_{1,\text{macro}}$  : moyenne des C scores par classe

TP = 4, FP = 1, FN = 4 → P = 0,8 ; R = 0,5 ;  $F_1 \approx 0,615$ . Deux  $F_1$  de 0,9 et 0,3 donnent macro = 0,6.



# Diagnostiquer avant de multiplier les époques

SPE  
DATA/IA

| Observation                   | Hypothèse              | Vérification               |
|-------------------------------|------------------------|----------------------------|
| Train progresse, val régresse | Surapprentissage       | Courbes + erreurs          |
| Tout prédit une classe        | Labels ou déséquilibre | Distribution + mapping     |
| Loss non finie                | Instabilité numérique  | Entrées + dtype + réglages |
| Score presque parfait         | Jeu facile ou fuite    | Groupes + doublons         |




# NER : retrouver des segments et leur type

SPE  
DATA/IA

| Mot    | Étiquette BIO | Signification        |
|--------|---------------|----------------------|
| Marie  | B-PER         | Début d'une personne |
| Dupont | I-PER         | Suite de la personne |
| habite | O             | Hors entité          |
| à      | O             | Hors entité          |
| Lyon   | B-LOC         | Début d'un lieu      |



# Un mot annoté peut devenir plusieurs sous-tokens

SPE  
DATA/IA

-100 : pas de contribution à la loss

Convention du TP : superviser le premier sous-token ; -100 ignore les autres dans la loss.



# Deux masques, deux questions différentes

`attention_mask = 0` : cette place correspond au padding de l'entrée.

`labels = -100` : cette position ne contribue pas à la loss.



Un sous-token ignoré dans la loss peut rester visible dans le contexte.

Le collator doit aussi compléter les labels avec la valeur ignorée.



# Des logits aux entités : ne pas perdre l'alignement

**Batch × longueur × nombre de labels → labels → segments.**

Prendre une classe par position selon le décodage retenu.

SPE  
DATA/IA

Retirer les positions ignorées avec le même masque que les cibles.

Reconstruire les séquences de labels dans l'ordre des mots.

Inspecter un exemple complet avant de calculer le score global.



# En NER, la frontière fait partie de la réponse

| Référence          | Prédiction  | Résultat strict      |
|--------------------|-------------|----------------------|
| Marie Dupont : PER | Marie : PER | Frontière incorrecte |
| Lyon : LOC         | Lyon : ORG  | Type incorrect       |
| AB123 : REF        | AB123 : REF | Entité correcte      |

SPE  
DATA/IA

Évaluer les entités complètes : début, fin et type.



# Une convention d'annotation vaut mieux qu'un débat sans règle

Décider si « Mme Dupont » inclut le titre.

Distinguer une ville d'une organisation portant le même nom.

SPE  
DATA/IA

Conserver les désaccords et leurs décisions de résolution.

Vérifier les frontières avant de chercher un meilleur modèle.



# Comparer un Transformer à la baseline équitabement

SPE  
DATA/IA

| À conserver        | Pourquoi                | À rapporter          |
|--------------------|-------------------------|----------------------|
| Mêmes partitions   | Même nouveauté évaluée  | Tailles et groupes   |
| Mêmes labels       | Même tâche              | Mapping des classes  |
| Même métrique      | Même règle de score     | Macro-F1 + classes   |
| Mêmes cas examinés | Comparaison des erreurs | Gains et régressions |



# Sauvegarder pour recharger, pas seulement pour archiver

Modèle, tokenizer et correspondance des labels vont ensemble.

Conserver configuration, versions, partitions et métriques.

SPE  
DATA/IA

Tester une prédiction après rechargement dans un objet neuf.

Exporter les artefacts hors de la session Colab éphémère.



# Du batch à la métrique : retrouver les responsabilités

Une loss train faible garantit-elle une bonne validation ?

Pourquoi un token peut-il avoir `attention_mask = 1` et `label = -100` ?

SPE  
DATA/IA

Marie au lieu de Marie Dupont : entité exacte ou erreur de frontière ?

Quel objet faut-il recharger avec les poids du classifieur ?



# TP 3A · Préparer et entraîner le classifieur

**Notebook 03\_j3\_classification.ipynb · 70 min**

Réutiliser les cinq intentions et la séparation par groupes.



Inspecter tokenizer, collator, labels et logits.

Lancer une courte adaptation de DistilBERT multilingue.

Livrable : configuration et courbes réellement observées.



# TP 3B · Comparer puis transférer à des critiques réelles

**Notebook 03\_j3\_classification.ipynb · 70 min**

30 min : comparer les modèles support, analyser et exporter pour J5.

SPE  
DATA/IA

40 min : adapter le classifieur au sentiment sur Allociné.

Sous-ensembles : 1 000 train, 200 validation et 200 test.

Livrables distincts : routeur support et modèle de sentiment.



# TP 3C · Aligner les mots, les sous-tokens et les labels

Notebook 04\_j3\_ner.ipynb · 50 min

Lire la convention d'entités du jeu fourni.



Construire l'alignement avec `word_ids()`.

Vérifier tokens spéciaux, continuations et padding à -100.

Livrable : tableau d'alignement validé avant entraînement.



# TP 3D · Mesurer des entités complètes

**Notebook 04\_j3\_ner.ipynb · 50 min**

Lancer l'entraînement réduit puis reconstruire les séquences.



Vérifier un cas sequeval strict à la main.

Distinguer erreurs de type et erreurs de frontière.

Livrable : métriques, exemples annotés et modèle sauvegardé.



# 04 / Adapter un petit LLM efficacement

Données de qualité, supervision explicite et budget GPU maîtrisé.

Matin : SFT, LoRA, QLoRA, résumé et fidélité.  
Après-midi : 160 min de SFT puis 80 min de résumé.



# Prompt, RAG ou fine-tuning : quel problème résoudre ?

| Besoin                        | Premier levier             | Limite à vérifier                 |
|-------------------------------|----------------------------|-----------------------------------|
| Clarifier une consigne        | Prompt + exemples          | Sensibilité à la formulation      |
| Consulter des faits évolutifs | Recherche + contexte (RAG) | Qualité des sources retrouvées    |
| Stabiliser un style ou format | SFT                        | Qualité et diversité des exemples |
| Améliorer la tâche            | Comparer les approches     | Coût et généralisation            |

SPE  
DATA/IA



# SFT : montrer les réponses que l'on souhaite obtenir

**Une consigne, une entrée et une réponse cible cohérente.**

Le modèle conserve l'objectif de prédiction du token suivant.

SPE  
DATA/IA

Les exemples orientent le comportement vers une tâche.

Le format des messages doit correspondre au checkpoint.

La réussite se mesure sur des demandes absentes de l'entraînement.



# Une bonne démonstration enseigne aussi les limites

**Message : « Mon paiement apparaît deux fois. »**

Réponse utile : reconnaître le doublon signalé et demander la vérification nécessaire.

**SPE  
DATA/IA**

Réponse risquée : annoncer un remboursement sans preuve.

Conserver le format cible sur toutes les démonstrations.

Inclure des cas ambigus et des informations manquantes.



# Curater : garder des exemples utiles et traçables

Dédupliquer avant la séparation, avec une politique explicite.

Contrôler contradictions, format, longueurs et données sensibles.


SPE  
DATA/IA

Séparer par scénario pour limiter les paraphrases partagées.

Conserver des cas de validation et de test sans les réécrire après coup.



# Le chat template transforme les rôles en tokens



Exemple de marqueurs Qwen ; utiliser le template associé au checkpoint.

# Superviser la réponse, garder la question dans le contexte


|           | Contexte fourni |       |       | Réponse cible |        | Padding |
|-----------|-----------------|-------|-------|---------------|--------|---------|
| Tokens    | [SYS]           | [USR] | [AST] | livraison     | EOS    | PAD     |
| Attention | 1               | 1     | 1     | 1             | 1      | 0       |
| Labels    | -100            | -100  | -100  | ID            | ID_EOS | -100    |

Visibilité du contexte  $\neq$  supervision de la loss

Le prompt reste visible ; la loss porte ici sur la réponse et sa fin de séquence.



# Le décalage causal ne doit se produire qu'une fois



Chaque logit à la position t vise le token t+1 ; appliquer ce décalage une seule fois.



# LoRA : apprendre une petite correction de matrice

$$\mathbf{y} = W_0 \mathbf{x} + \frac{\alpha}{r} B A \mathbf{x}$$

SPE  
DATA/IA

Ajouter une correction entraînable de faible rang à une matrice gelée.

$\mathbf{x}$  : entrée  $d_{in}$  ;  $\mathbf{y}$  : sortie  $d_{out}$

$W_0$  : matrice gelée,  $d_{out} \times d_{in}$

$A$  :  $r \times d_{in}$  ;  $B$  :  $d_{out} \times r$

$r$  : rang choisi pour la correction

$\alpha/r$  : facteur d'échelle de la correction

$W_0 = I, \mathbf{x} = (2 ; 1), A = [1, -1], B = (0,5 ; 1), \alpha/r = 1 \rightarrow \mathbf{y} = (2,5 ; 2).$



# LoRA : combien de paramètres apprend-on ?

$$N_{\text{complet}} = d_{\text{out}} d_{\text{in}}$$

$$N_{\text{LoRA}} = r (d_{\text{in}} + d_{\text{out}})$$

SPE  
DATA/IA

Compter les deux petites matrices, puis comparer à la matrice complète.

$d_{\text{in}}, d_{\text{out}}$  : dimensions d'entrée et de sortie

$r$  : rang de l'adaptateur


$N_{\text{complet}}$  : paramètres de la matrice pleine

$N_{\text{LoRA}}$  : paramètres entraînaables de A et B

$1\,024^2 = 1\,048\,576$  ;  $r = 8 \rightarrow 16\,384$  paramètres LoRA, soit 1,5625 % pour cette matrice.



# QLoRA : quantifier la base, entraîner les adaptateurs



Base stockée en NF4 ; calcul en FP16 ici ; seuls les adaptateurs sont entraînables.

# La mémoire des poids n'est pas la mémoire totale

$$M_{\text{total}} \approx M_{\text{poids}} + M_{\text{gradients}} + M_{\text{optimiseur}} \\ + M_{\text{activations}} + M_{\text{buffers}}$$

SPE  
DATA/IA

Les poids ne représentent qu'une partie de la mémoire nécessaire.

M\_total : mémoire totale approximative

M\_poids : paramètres du modèle et adaptateurs

M\_gradients, M\_optimiseur : états d'apprentissage

M\_activations : valeurs intermédiaires conservées

M\_buffers : mémoire de travail et autres tampons

**0,5 milliard × 2 octets = 1 Go de poids FP16 idéalisés, avant activations et autres états.**



# Quatre leviers à régler avec une raison

| Levier        | Ce qu'il change         | Contrepartie                    |
|---------------|-------------------------|---------------------------------|
| Longueur max  | Tokens conservés        | Risque de couper la réponse     |
| Micro-batch   | Activations simultanées | Plus de passes                  |
| Accumulation  | Batch effectif          | Temps et détails d'optimisation |
| Checkpointing | Activations stockées    | Recalcul supplémentaire         |

SPE  
DATA/IA



# Après l'entraînement : base + adaptateur + tokenizer

Sauvegarder l'adaptateur et sa configuration.

Retrouver le même checkpoint de base et la même révision.


SPE  
DATA/IA

Recharger l'ensemble dans un objet neuf pour tester l'inférence.

Comparer base et adaptation avec les mêmes prompts et réglages.



# Résumer : conserver les faits utiles sous une contrainte

SPE  
DATA/IA

Chaque affirmation du résumé doit être étayée par un fait de la source.



# ROUGE mesure un recouvrement, pas la vérité

ROUGE-1 : recouvrement d'unités lexicales selon la tokenisation.

ROUGE-L : similarité fondée sur une sous-séquence commune.

SPE  
DATA/IA

Une bonne paraphrase peut partager peu de mots.

Une phrase presque identique peut inverser un fait crucial.



# Relier chaque affirmation à une preuve dans la source

| Affirmation du résumé           | Présente dans la source ? | Verdict            |
|---------------------------------|---------------------------|--------------------|
| Colis AB123 reçu mardi          | Oui                       | Conservée          |
| Un article manque               | Oui                       | Conservée          |
| Remboursement effectué          | Non                       | Invention          |
| Client demande une vérification | Oui, mais omise           | Information perdue |

SPE  
DATA/IA



# Vérifier ce qui est réellement entraîné et évalué

SFT et LoRA désignent-ils la même chose ?

QLoRA signifie-t-il que tous les calculs se font en 4 bits ?



Pourquoi inspecter les labels du batch SFT ?

Un meilleur ROUGE prouve-t-il un résumé plus fidèle ?



# TP 4A · Préparer les démonstrations et la supervision

**Notebook 05\_j4\_sft\_lora.ipynb · 80 min**

Auditer les paires prompt/completion et les partitions.

**SPE**  
**DATA/IA**

Afficher le rendu du chat template de Qwen.

Inspecter le batch réel et les positions labels = -100.

Livrable : cinq exemples validés et masque expliqué.



# TP 4B · Entraîner un adaptateur et mesurer l'effet

Notebook 05\_j4\_sft\_lora.ipynb · 80 min

Inspecter modules ciblés et paramètres entraînables.

SPE  
DATA/IA

Mesurer une étape avant de lancer la courte expérience.

Comparer base et adaptateur sur les mêmes cas réservés.

Livrable : adaptateur rechargeable, sorties et limites.



# TP 4C · Fine-tuner un LoRA dédié au résumé

**Notebook 06\_j4\_resume\_evaluation.ipynb · 40 min**

Inspecter 16 comptes rendus train, 2 validation et 4 test.

**SPE**  
**DATA/IA**

Préparer le template et la supervision des réponses de résumé.

Lancer 12 pas LoRA sur le modèle de base, selon le budget réel.

Livrable : adaptateur résumé distinct de celui du support.



# TP 4D · Comparer extractif, base et résumé adapté

Notebook 06\_j4\_resume\_evaluation.ipynb · 40 min

Évaluer les trois méthodes sur les mêmes 4 textes test réservés.



Confronter ROUGE à fidélité, couverture et format.

Annoter omissions, contradictions et ajouts non étayés.

Livrable : sorties comparées, adaptateur et conclusion prudente.



# 05 / Évaluer, présenter et défendre un système

SPE  
DATA/IA

Le résultat utile est une décision accompagnée de preuves.

Matin : protocole, erreurs, coût, démo et documentation.  
Après-midi : mini-projet comparatif et soutenances.

92



# Avant le score, écrire le contrat d'évaluation

Quelle tâche et quelle population de messages ?

Quelle référence, quelle métrique et quel coût d'erreur ?

Quelles données sont réservées à la décision finale ?

Quelle preuve ferait changer notre choix de modèle ?



# Comparer qualité, coût et fiabilité d'exécution

| Axe              | Mesure possible                | Question                      |
|------------------|--------------------------------|-------------------------------|
| Qualité          | Macro-F1, F1 entités, grille   | La tâche est-elle réussie ?   |
| Coût             | Temps, mémoire, taille         | À quel prix technique ?       |
| Robustesse       | Cas difficiles et hors domaine | Quand cela échoue-t-il ?      |
| Reproductibilité | Rechargement et versions       | Peut-on refaire le résultat ? |

SPE  
DATA/IA

# Une baseline zéro-shot exige aussi un protocole

**Demander au LLM un label parmi les cinq classes, sans exemples d'entraînement dans le prompt.**

Définir les classes et le format de sortie dans une consigne fixe.

**SPE**  
**DATA/IA**

Fixer le décodage et la règle de parsing.

Compter les sorties invalides au lieu de les faire disparaître.

Employer les mêmes messages test que pour les autres méthodes.



# La métrique dépend de l'unité de réussite

| Tâche          | Unité évaluée                  | Mesure de départ       |
|----------------|--------------------------------|------------------------|
| Classification | Message + classe               | Macro-F1 et matrice    |
| NER            | Segment + type                 | F1 d'entités strict    |
| Recherche      | Requête + documents pertinents | Recall@k défini        |
| Résumé         | Faits et texte                 | ROUGE + grille humaine |

SPE  
DATA/IA

# Découper les résultats pour trouver les fragilités

Messages courts contre messages longs.

Une intention contre plusieurs demandes.



Formulation fréquente contre paraphrase nouvelle.

Français standard contre fautes, accents manquants ou mélange de langues.



# Un petit test produit un résultat incertain

**Sur 20 exemples, une erreur de plus change l'accuracy de 5 points.**

Rapporter le nombre d'exemples avec chaque score.

SPE  
DATA/IA

Comparer les mêmes cas, pas deux échantillons différents.

Distinguer variation de données et variation d'entraînement.

Utiliser rééchantillonnage ou répétitions seulement avec un protocole clair.



# Une grille humaine doit rendre les jugements comparables

SPE  
DATA/IA

| Critère    | 0                       | 1                     | 2                 |
|------------|-------------------------|-----------------------|-------------------|
| Fidélité   | Fait inventé/contredit  | Ambiguïté mineure     | Faits étayés      |
| Couverture | Information clé absente | Partielle             | Essentiel présent |
| Format     | Inexploitable           | Correction nécessaire | Conforme          |
| Lisibilité | Confus                  | Compréhensible        | Clair et concis   |



# Un LLM juge peut aider, mais il faut aussi le contrôler

Donner une grille précise et les éléments de référence.

Masquer l'identité des systèmes comparés.

Tester l'effet de l'ordre des réponses.

Vérifier un échantillon humain avant d'utiliser ses notes.

100



# Analyser une erreur pour décider d'une action

| Erreur observée              | Cause à vérifier          | Action possible               |
|------------------------------|---------------------------|-------------------------------|
| Mauvais label de référence   | Convention ambiguë        | Clarifier et tracer           |
| Indice en fin de texte perdu | Troncature                | Adapter longueur/segmentation |
| Sortie LLM invalide          | Consigne ou décodage      | Fixer format + validation     |
| Fait inventé                 | Source absente ou ignorée | Contexte + contrôle           |

SPE  
DATA/IA

# Tester la robustesse avec des variations contrôlées

**Changer une chose à la fois pour savoir ce qui casse.**

Paraphrase : même intention, autre formulation.

SPE  
DATA/IA

Négation : sens modifié avec peu de mots nouveaux.

Référence : même phrase, identifiant différent.

Hors domaine : demande qui ne correspond à aucune classe.



# Mesurer la latence dans des conditions compréhensibles

Séparer chargement initial et inférence à chaud.

Fixer batch, longueur d'entrée et longueur de sortie.

SPE  
DATA/IA

Sur GPU, synchroniser correctement la mesure du calcul.

Rapporter matériel, répétitions et distribution des temps.



# Une démo Gradio rend le comportement inspectable

Un champ texte, une sortie lisible et quelques exemples choisis.

Charger le modèle une fois, puis appeler une fonction d'inférence.

SPE  
DATA/IA

Prévoir entrée vide, texte long et message d'erreur compréhensible.

Lancement local au notebook ; partage public désactivé par défaut.



# Le livrable doit raconter comment le résultat a été obtenu

README : objectif, lancement et limites.

Model card : base, adaptation, données, métriques et usages prévus.



Data card : origine, schéma, construction, partitions et licence.

Artefacts : configuration, prédictions, modèle ou adaptateur et tokenizer.



# Publier sur le Hub : rendre l'artefact réutilisable

Vérifier la licence du modèle de base et des données.

Choisir explicitement visibilité et fichiers à envoyer.



Pour LoRA, documenter la dépendance au checkpoint de base.

Publication facultative ; dépôt privé proposé dans le TP.



# Mini-projet : une décision défendable en binôme

SPE  
DATA/IA

| Critère                       | Points / 20 | Preuve attendue                   |
|-------------------------------|-------------|-----------------------------------|
| Protocole et absence de fuite | 4           | Tâche, groupes, validation, test  |
| Comparaison équitable         | 4           | Méthodes identifiées, mêmes cas   |
| Évaluation et analyse         | 4           | Métriques, erreurs, robustesse    |
| Reproductibilité + démo/card  | 6           | 3 points chacun : export et usage |
| Soutenance individuelle       | 2           | Argumentation des deux membres    |



# Soutenir : problème, preuve, décision, limite

1 min : tâche et protocole.

2 min : comparaison et exemple d'erreur.



1 min : démo avec un cas difficile.

1 min : décision, limite et prochaine expérience.



# Avant de conclure : que peut-on réellement affirmer ?

Une démo qui fonctionne prouve-t-elle la généralisation ?

Que faire d'une sortie zéro-shot hors des cinq labels ?

Que signifie un gain d'un exemple sur vingt ?

Quelle preuve permet à un autre binôme de reproduire le résultat ?



# TP 5A · Verrouiller le protocole et lancer les références

**Notebook 07\_j5\_projet.ipynb · 75 min**

Définir tâche, critères et jeux réservés.

**SPE**  
**DATA/IA**

Charger la baseline et, si disponible, l'archive du jour 3.

Préparer le zéro-shot avec prompt et parsing fixes.

Livrable : premières prédictions et contrat d'expérience.



# TP 5B · Tester une amélioration et lire les erreurs

Notebook 07\_j5\_projet.ipynb · 75 min

Choisir une hypothèse à partir des erreurs de validation.

SPE  
DATA/IA

Modifier un seul facteur et comparer les mêmes cas.

Exécuter le test final après sélection.

Livrable : table comparative, cinq erreurs et mesure de coût.



# TP 5C · Préparer une démo et un livrable rechargeable

Notebook 07\_j5\_projet.ipynb · 40 min

Construire l'interface Gradio et tester ses entrées limites.



Rédiger README, model card et limites des données.

Vérifier les fichiers et le rechargement de l'artefact.

Livrable : archive locale ; publication privée seulement si choisie.



# TP 5D · Soutenances, revue croisée et bilan

**Notebook 07\_j5\_projet.ipynb · 50 min**

Présenter la tâche, le protocole et les résultats en cinq minutes.

**SPE**  
**DATA/IA**

Montrer un cas difficile et expliquer une limite.

Faire tester le rechargement ou la démo par un autre groupe.

Conclure par la prochaine expérience la plus utile.

